

André Takeo Loschner Fujiwara

**Predição de Direção de Preços de Ações
Brasileiras
com Sentimento de Notícias Financeiras:
Pipeline, Ilusão e Autocorreção Metodológica**

São Paulo

2026

André Takeo Loschner Fujiwara

**Predição de Direção de Preços de Ações Brasileiras
com Sentimento de Notícias Financeiras:
Pipeline, Ilusão e Autocorreção Metodológica**

Trabalho de Conclusão de Curso apresentado
ao Curso de Ciência de Dados e Inteligência
Artificial da PUC-SP como requisito parcial
para a obtenção do grau de Bacharel.

PUC-SP

Curso de Ciência de Dados e Inteligência Artificial

Orientador: Prof. Eric Bacconi Gonçalves

São Paulo
2026

Resumo

Este trabalho investiga se notícias financeiras brasileiras podem melhorar a predição de direção de preços de ações da B3, utilizando como estudo de caso três ações de grande capitalização: ITUB4 (Itaú Unibanco), PETR4 (Petrobras) e VALE3 (Vale). O *pipeline* proposto coleta artigos do portal InfoMoney, extrai representações de sentimento via FinBERT-PT-BR — um modelo BERT especializado em textos financeiros em português (SOUZA; CARVALHO; CALADO, 2023) — e combina as *features* resultantes com dados de mercado do Yahoo Finance para treinar classificadores binários (sobe/desce).

O trabalho documenta uma autocorreção metodológica incomum: sob avaliação por janela única (*walk-forward split* 70/15/15), o modelo Transformer (VASWANI et al., 2017) atinge ROC-AUC de 0,709, aparentemente demonstrando que o sentimento financeiro específico supera *embeddings* genéricos de alta dimensionalidade. Porém, uma investigação sistemática com mais de 1.500 execuções de modelo — incluindo análise *multi-seed* (20 sementes), validação cruzada *expanding-window* (até 52 *folds*), testes de Wilcoxon *signed-rank*, intervalos de confiança *bootstrap* e *ablation* de *features* — revela que o resultado é um artefato: o Transformer exibe colapso bimodal (AUC oscilando entre 0,08 e 0,93 conforme a semente), e sob avaliação multi-fold o sentimento adiciona $\Delta = +0,003$ ao *baseline* autoregressivo (Wilcoxon $p = 0,49$, IC 95% $[-0,012; +0,018]$).

A contribuição central é a demonstração empírica, em dados brasileiros, de como a avaliação por janela única pode inverter a conclusão qualitativa de um estudo em *machine learning* financeiro — transformando um achado aparentemente positivo em um resultado nulo — e a proposição de protocolos mínimos de avaliação para mitigar esse viés.

Palavras-chave: Predição de preços. Sentimento financeiro. FinBERT. Avaliação metodológica. Séries temporais financeiras. B3.

Abstract

This work investigates whether Brazilian financial news can improve stock price direction prediction for B3 equities, using three large-cap stocks as case studies: ITUB4 (Itaú Unibanco), PETR4 (Petrobras), and VALE3 (Vale). The proposed pipeline collects articles from the InfoMoney portal, extracts sentiment representations via FinBERT-PT-BR — a BERT model fine-tuned on Brazilian Portuguese financial text — and combines the resulting features with Yahoo Finance market data to train binary classifiers (up/down). This work documents an uncommon methodological self-correction: under single-window evaluation (70/15/15 walk-forward split), the Transformer model achieves ROC-AUC of 0.709, apparently demonstrating that domain-specific financial sentiment outperforms high-dimensional generic embeddings. However, a systematic investigation comprising over 1,500 model runs — including multi-seed analysis (20 seeds), expanding-window cross-validation (up to 52 folds), Wilcoxon signed-rank tests, bootstrap confidence intervals, and feature ablation — reveals the result to be an artifact: the Transformer exhibits bimodal collapse (AUC ranging from 0.08 to 0.93 depending on seed), and under multi-fold evaluation sentiment adds $\Delta = +0.003$ over the autoregressive baseline (Wilcoxon $p = 0.49$, 95% CI $[-0.012, +0.018]$).

The central contribution is an empirical demonstration, on Brazilian data, of how single-window evaluation can reverse the qualitative conclusion of a financial machine learning study — turning an apparently positive finding into a null result — along with minimal evaluation protocols to mitigate this bias.

Keywords: Price prediction. Financial sentiment. FinBERT. Methodological evaluation. Financial time series. B3.

Lista de ilustrações

- Figura 1 – Distribuição de AUC sobre 20 sementes em ITUB4. O Transformer (esquerda) exibe distribuição bimodal com AUCs agrupados próximos de 0 e 1, enquanto o *baseline* (direita) é estável em torno de 0,64. Coeficiente de variação do Transformer: 38%. 19
- Figura 2 – AUC por *fold* ao longo do tempo sob *expanding-window* CV, para os 3 ativos. A linha do *baseline* (vermelho) permanece consistentemente acima do Transformer (azul) em ITUB4 e PETR4, com barras de erro menores. 19
- Figura 3 – Distribuição de 880 AUCs ($52 \text{ folds} \times 10 \text{ sementes}$) em VALE3. O *baseline* (esquerda) produz distribuição unimodal centrada em $\sim 0,55$. O Transformer (direita) produz distribuição bimodal severa com picos em $\text{AUC} < 0,05$ e $\text{AUC} > 0,95$ — assinatura de classificador degenerado. 20
- Figura 4 – Distribuição de AUC por configuração de *features* e ativo, sob *expanding-window* CV. PRICE e PRICE+SENT são estatisticamente indistinguíveis; SENT sozinho opera abaixo do acaso. 21
- Figura 5 – Validação do TCN [32,32]. Esquerda: distribuição multi-seed (20 sementes) — 60% das sementes ficam abaixo de 0,50. Direita: distribuição *expanding-window* CV — AUC médio de 0,556, inferior ao *baseline*. . . 21

Lista de tabelas

Tabela 1	– Volume de artigos coletados por ativo.	13
Tabela 2	– Resultados com <i>embeddings</i> genéricos Ollama (Etapa 3).	14
Tabela 3	– Comparação Etapa 3 (<i>embeddings</i>) vs Etapa 4 (sentimento FinBERT).	16
Tabela 4	– Experimentos do Capítulo 5.	17
Tabela 5	– Hierarquia de <i>baselines</i> : do ingênuo ao autoregressivo.	18
Tabela 6	– Distribuição de AUC sobre 20 sementes (ITUB4, janela única).	18
Tabela 7	– AUC médio sob <i>expanding-window</i> CV.	19
Tabela 8	– Ablation: PRICE vs SENT vs PRICE+SENT.	20

Lista de abreviaturas e siglas

AUC	<i>Area Under the ROC Curve</i>
B3	Brasil, Bolsa, Balcão
BERT	<i>Bidirectional Encoder Representations from Transformers</i>
BiLSTM	<i>Bidirectional Long Short-Term Memory</i>
CI	Intervalo de Confiança (<i>Confidence Interval</i>)
CV	Validação Cruzada (<i>Cross-Validation</i>)
ECE	<i>Expected Calibration Error</i>
FinBERT	<i>Financial BERT</i>
LSTM	<i>Long Short-Term Memory</i>
MDE	Tamanho Mínimo de Efeito Detectável
NLP	Processamento de Linguagem Natural
OHLCV	<i>Open, High, Low, Close, Volume</i>
PCA	Análise de Componentes Principais
ROC	<i>Receiver Operating Characteristic</i>
SHAP	<i>SHapley Additive exPlanations (??)</i>
TCN	<i>Temporal Convolutional Network</i>
XGB	XGBoost (<i>eXtreme Gradient Boosting</i>)

Sumário

1	INTRODUÇÃO	9
1.1	Problema de pesquisa	9
1.2	Objetivos	9
1.2.1	Objetivo geral	9
1.2.2	Objetivos específicos	10
1.3	Justificativa	10
1.4	Estrutura do trabalho	10
2	REVISÃO BIBLIOGRÁFICA	11
2.1	Hipótese de eficiência de mercado	11
2.2	NLP aplicado a finanças	11
2.3	Arquiteturas de modelos	12
2.4	Protocolos de avaliação em ML financeiro	12
3	PIPELINE: COLETA, ENGENHARIA DE FEATURES E MODELOS INICIAIS	13
3.1	Coleta de notícias financeiras	13
3.2	Engenharia de features	13
3.3	Modelos iniciais com embeddings genéricos	14
4	SENTIMENTO FINANCEIRO ESPECÍFICO VIA FINBERT-PT-BR	15
4.1	Hipótese	15
4.2	O modelo FinBERT-PT-BR	15
4.3	Pipeline de extração e resultados	15
5	INVESTIGAÇÃO METODOLÓGICA E O VIÉS DA AVALIAÇÃO POR JANELA ÚNICA	17
5.1	Motivação e protocolo geral	17
5.2	Baseline autoregressivo e baselines ingênuos	18
5.3	Reprodutibilidade e variância de semente	18
5.4	Expanding-window cross-validation	18
5.5	Ablation: o sentimento adiciona algo?	19
5.6	Validação do TCN Stage 5b	20
5.7	Síntese	20
6	CONCLUSÃO	22
6.1	Contribuições	22

6.2	Reflexão sobre o processo de autocorreção	22
6.3	Limitações	23
6.4	Trabalhos futuros	23
	REFERÊNCIAS	24
	APÊNDICE A – FUNÇÕES UTILITÁRIAS DE AVALIAÇÃO	26
	APÊNDICE B – ARQUITETURA TCN	27

1 Introdução

A predição de direção de preços de ações é um problema central em finanças quantitativas, situado na interseção entre a hipótese de eficiência de mercado (FAMA, 1970) e a evidência empírica de previsibilidade parcial em horizontes curtos (LO, 2004). Com o avanço das técnicas de processamento de linguagem natural (NLP), uma linha de pesquisa crescente investiga se informações textuais — notícias, relatórios de analistas, publicações em redes sociais — podem ser incorporadas como *features* preditivas em modelos de *machine learning* para complementar dados tradicionais de preço e volume (XU; COHEN, 2018; ARACI, 2019).

No contexto brasileiro, a pesquisa nesta área é ainda incipiente. A B3 (Brasil, Bolsa, Balcão) apresenta características que a distinguem de mercados desenvolvidos: menor liquidez em ações fora do índice principal, concentração de informação em poucas fontes jornalísticas especializadas, e um ecossistema de NLP em português que só recentemente passou a dispor de modelos de linguagem específicos para o domínio financeiro, como o FinBERT-PT-BR (SOUZA; CARVALHO; CALADO, 2023).

1.1 Problema de pesquisa

O problema central pode ser formulado como: **notícias financeiras brasileiras melhoram a predição de direção de preço (sobe/desce) de ações da B3?** Esta questão desdobra-se em duas dimensões:

- (a) **Representação textual:** qual forma de codificar o conteúdo de notícias — *embeddings* genéricos de alta dimensionalidade ou sentimento financeiro específico de baixa dimensionalidade — produz *features* mais informativas para a predição?
- (b) **Robustez metodológica:** os resultados obtidos sob protocolos de avaliação padrão da literatura (*walk-forward split* único) sobrevivem a escrutínio com validação cruzada *expanding-window*, múltiplas sementes e testes estatísticos formais?

1.2 Objetivos

1.2.1 Objetivo geral

Investigar empiricamente se *features* de sentimento extraídas de notícias financeiras brasileiras adicionam poder preditivo a modelos de classificação binária de direção de preço de ações da B3, sob avaliação metodologicamente rigorosa.

1.2.2 Objetivos específicos

1. Construir um *pipeline* de coleta, processamento e integração de notícias financeiras do portal InfoMoney com dados de mercado do Yahoo Finance.
2. Comparar duas estratégias de representação textual: *embeddings* genéricos de 1.024 dimensões (Ollama `qwen3-embedding:4b`) e sentimento financeiro de 5 dimensões (FinBERT-PT-BR).
3. Treinar e avaliar modelos de classificação binária (BiLSTM, Transformer, XGBoost, TCN) sobre as representações textuais combinadas com *features* de preço.
4. Aplicar protocolos de avaliação rigorosa — *bootstrap* CI, análise *multi-seed*, validação cruzada *expanding-window*, *ablation* de *features* — para determinar a robustez dos resultados.
5. Documentar e analisar as discrepâncias entre avaliação por janela única e avaliação multi-fold, contribuindo para a literatura de avaliação metodológica em ML financeiro.

1.3 Justificativa

A relevância deste trabalho reside em três aspectos. Primeiro, a aplicação de NLP financeiro ao mercado brasileiro é pouco explorada, e a disponibilidade recente de modelos como o FinBERT-PT-BR abre oportunidades de investigação em português. Segundo, a literatura de *deep learning* aplicado a finanças sofre de um problema metodológico amplamente documentado — a avaliação por janela única em séries não-estacionárias (BAILEY et al., 2014; PRADO, 2018) — mas raramente demonstrado empiricamente com o grau de detalhe que este trabalho propõe. Terceiro, a autocorreção metodológica documentada nos Capítulos 4 e 5 constitui, por si só, uma contribuição pedagógica sobre as armadilhas da avaliação de modelos em finanças.

1.4 Estrutura do trabalho

O trabalho está organizado em seis capítulos. O Capítulo 2 apresenta a fundamentação teórica e a revisão bibliográfica. O Capítulo 3 descreve o *pipeline* completo: coleta de notícias, engenharia de *features* e treinamento inicial com *embeddings* genéricos. O Capítulo 4 introduz o FinBERT-PT-BR e documenta o resultado inicialmente promissor ($AUC = 0,709$). O Capítulo 5 conduz a investigação metodológica que revisa substancialmente esse resultado. O Capítulo 6 sintetiza as conclusões e propõe direções futuras.

2 Revisão Bibliográfica

Este capítulo apresenta os fundamentos teóricos que sustentam o trabalho: a hipótese de eficiência de mercado e suas implicações para a previsibilidade de preços, o uso de NLP em finanças, e os protocolos de avaliação em *machine learning* para séries temporais financeiras.

2.1 Hipótese de eficiência de mercado

A hipótese de eficiência de mercado (HEM), formalizada por Fama (1970), postula que os preços dos ativos refletem toda a informação disponível. Em sua forma semiforte, a HEM implica que informações públicas — incluindo notícias financeiras — já estão incorporadas nos preços no momento de sua publicação, tornando impossível obter retornos sistematicamente superiores com base nessas informações. Trabalhos empíricos subsequentes, contudo, documentaram anomalias que sugerem previsibilidade parcial. Lo (2004) propôs a Hipótese de Mercados Adaptativos, na qual a eficiência varia ao longo do tempo conforme as condições de mercado e o comportamento dos agentes.

A tensão entre eficiência teórica e previsibilidade empírica é o pano de fundo deste trabalho: se os preços já incorporam o sentimento das notícias, nenhum modelo deveria superá-los consistentemente; se não incorporam, há espaço para predição.

2.2 NLP aplicado a finanças

A aplicação de processamento de linguagem natural à predição de preços passou por três gerações de representação textual. A primeira utilizou léxicos de sentimento construídos manualmente, como o Loughran-McDonald (LOUGHRAN; MCDONALD, 2011), atribuindo polaridade a palavras individuais. A segunda introduziu *embeddings* densos baseados em redes neurais, como Word2Vec e GloVe, que capturam relações semânticas mas não são específicos ao domínio financeiro. A terceira geração, atual, utiliza modelos de linguagem pré-treinados e *fine-tuned* para o domínio, como o FinBERT (ARACI, 2019) e suas variantes regionais, incluindo o FinBERT-PT-BR para português brasileiro (SOUZA; CARVALHO; CALADO, 2023).

É importante notar que resultados nulos ou negativos são sub-representados na literatura de NLP financeiro devido ao viés de publicação. ?? documentaram que muitos estudos de *sentiment analysis* para previsão de ações não replicam quando avaliados fora da amostra original. Kelly e Xiu (2023) mostraram que a maior parte do poder preditivo de variáveis

textuais desaparece quando se controla adequadamente por *features* de preço — resultado alinhado com os achados deste trabalho.

Xu e Cohen (2018) demonstraram que a combinação de texto de *tweets* com séries históricas de preço melhora a predição de direção em ações do S&P 500, utilizando um modelo de atenção hierárquico. Fischer e Krauss (2018) aplicaram LSTMs (*Long Short-Term Memory*, proposta originalmente por Hochreiter e Schmidhuber (1997)) à predição de retornos diários de ações do S&P 500, reportando resultados superiores ao *buy-and-hold* em períodos específicos. No contexto brasileiro, Cavalcante et al. (2016) utilizaram análise de sentimento de notícias em português para predição de volatilidade do IBOVESPA, e Santos e Silva (2020) aplicaram modelos BERT a textos financeiros da CVM.

2.3 Arquiteturas de modelos

Este trabalho utiliza quatro famílias de modelos. O BiLSTM (HOCHREITER; SCHMIDHUBER, 1997) processa sequências temporais bidirecionalmente, capturando dependências de longo prazo. O Transformer (VASWANI et al., 2017) utiliza mecanismos de atenção *multi-head* que permitem capturar relações entre posições arbitrárias na sequência. O XGBoost (CHEN; GUESTRIN, 2016), um algoritmo de *gradient boosting* sobre árvores de decisão, é o padrão de facto para dados tabulares. A TCN (*Temporal Convolutional Network*) (BAI; KOLTER; KOLTUN, 2018) aplica convoluções dilatadas causais, capturando padrões temporais locais com campo receptivo exponencialmente crescente.

2.4 Protocolos de avaliação em ML financeiro

A avaliação de modelos preditivos em séries temporais financeiras apresenta desafios específicos que a distinguem de problemas padrão de *machine learning*. Bailey et al. (2014) demonstraram formalmente que a otimização de estratégias sobre um único período de *backtest* inevitavelmente infla métricas de desempenho — o fenômeno que denominaram *backtest overfitting*. Prado (2018) sistematizou o problema, propondo validação cruzada com purga e embargo como padrão mínimo. Cawley e Talbot (2010) documentaram o viés de seleção de modelo, mostrando que a avaliação sobre o mesmo conjunto de dados usado para selecionar modelos produz estimativas otimistas mesmo sem vazamento explícito de dados.

A métrica ROC-AUC, embora amplamente utilizada, deve ser interpretada com cautela em conjuntos de teste pequenos. Hanley e McNeil (1982) derivaram o erro-padrão analítico da AUC, permitindo o cálculo de intervalos de confiança e tamanhos mínimos de efeito detectáveis — ferramenta essencial quando os conjuntos de teste têm 60–177 amostras, como neste trabalho.

3 Pipeline: Coleta, Engenharia de Features e Modelos Iniciais

Este capítulo descreve as três primeiras etapas do *pipeline*: coleta de notícias financeiras, engenharia de *features* (mercado e texto) e treinamento inicial de modelos com *embeddings* genéricos.

3.1 Coleta de notícias financeiras

O corpus textual foi construído a partir do portal InfoMoney, uma das principais fontes de notícias financeiras no Brasil. O módulo `extractor.py` acessa a REST API do WordPress do portal (`/wp-json/wp/v2/posts`), realizando buscas paginadas (100 artigos por página) para cada *ticker* analisado. Cada requisição HTTP possui mecanismo de retentativa: até 3 tentativas com *backoff* linear (1 s, 2 s), tratando erros de *timeout*, conexão e códigos de status 429/5xx. Os artigos passam por pré-processamento (remoção de *tags* HTML, decodificação de entidades, normalização de *whitespace*) e a extração ocorre em paralelo via `ThreadPoolExecutor`.

Tabela 1 – Volume de artigos coletados por ativo.

Ativo	Artigos	Período
ITUB4 (Itaú Unibanco)	2.572	2009–2026
PETR4 (Petrobras)	1.775	2009–2026
VALE3 (Vale)	1.525	2009–2026
Total	5.872	

3.2 Engenharia de features

O módulo `yahoo_finance.py` obtém dados OHLCV via `yfinance` e calcula 11 *features* técnicas por dia: fechamento, volume, retorno diário, médias móveis (7 e 21 dias), volatilidade (desvio-padrão 21 dias) e 5 valores defasados. O módulo `news_embedder.py` transforma cada artigo em um vetor de 1.024 dimensões via Ollama (`qwen3-embedding:4b`), com agregação diária por média ponderada por recência. As *features* são combinadas via *left join* por data com *forward-fill*. O *dataset* resultante contém 1.227 dias $\times$ 1.035 *features* (11 de preço + 1.024 de *embeddings*).

3.3 Modelos iniciais com embeddings genéricos

O alvo binário é definido como 1 se $\text{Close}[t + 21] > \text{Close}[t]$, com desbalanceamento de 59% “Sobe” / 41% “Desce”. Os *embeddings* são reduzidos para 32 componentes via PCA. A validação segue *split* cronológico 70/15/15.

Tabela 2 – Resultados com *embeddings* genéricos Ollama (Etapa 3).

Modelo	Arquitetura	ROC-AUC
BiLSTM Original	2 camadas, 128 <i>hidden</i> , 30% <i>dropout</i>	0,443
BiLSTM Reduzido	1 camada, 32 <i>hidden</i> , 50% <i>dropout</i>	0,505
Transformer	2 camadas, 4 cabeças, $d_{\text{model}} = 64$	0,568
XGBoost	300 árvores, profundidade 4	0,610

Todos os modelos apresentaram desempenho próximo do acaso, sugerindo que *embeddings* genéricos de alta dimensionalidade não são adequados para esta tarefa. O Capítulo 4 testa uma representação alternativa.

4 Sentimento Financeiro Específico via FinBERT-PT-BR

4.1 Hipótese

Os resultados do Capítulo 3 sugeriram que os *embeddings* genéricos contêm ruído semântico irrelevante para o domínio financeiro. Este capítulo testa se uma representação compacta e específica — 5 *features* de sentimento financeiro extraídas com o FinBERT-PT-BR (SOUZA; CARVALHO; CALADO, 2023) — pode ser mais informativa.

4.2 O modelo FinBERT-PT-BR

O FinBERT-PT-BR é um modelo BERT (DEVLIN et al., 2019) pré-treinado e *fine-tuned* em corpora financeiros brasileiros. Para cada artigo, produz três *logits* correspondentes às classes POSITIVO, NEGATIVO e NEUTRO. Diferentemente de modelos de sentimento genéricos, foi calibrado para vocabulário financeiro específico.

4.3 Pipeline de extração e resultados

A extração segue os passos: inferência em *batch* (32 artigos, entrada título + resumo, 512 *tokens*); persistência dos *logits* brutos; agregação diária em 5 *features* (`n_articles`, `mean_logit_pos/neg/neu`, `mean_sentiment`); junção temporal com *forward-fill*. O *dataset* resultante: 1.207 dias $\times$ 16 *features*.

Granularidade temporal e risco de *look-ahead*. Os artigos possuem *timestamps* ISO 8601, mas a agregação descarta o horário. Artigos pós-fechamento da B3 (~17h BRT) são atribuídos ao dia t ; o deslocamento pode exceder 1 dia em dias consecutivos sem publicação. O impacto é atenuado pelo horizonte de 5–21 dias e pela média diária.

Tratamento de desbalanceamento de classe. O alvo binário apresenta desbalanceamento de 59% “Sobe” / 41% “Desce” no conjunto de treino. Para mitigar o viés em direção à classe majoritária, todos os modelos recebem compensação explícita: os modelos neurais (BiLSTM, Transformer, TCN) utilizam `BCEWithLogitsLoss` com `pos_weight = n_desce/n_sobe  $\approx$  1,38`; o XGBoost utiliza o parâmetro `scale_pos_weight` com o mesmo valor; e os modelos *sklearn* (Logistic Regression, Random Forest) utilizam `class_weight="balanced"`. Apesar desta compensação, o Transformer ainda exhibe forte viés para a classe majoritária (prevendo “Desce” apenas 11 vezes em 177 amostras), indicando que o desbalanceamento é um fator contribuinte mas não a causa principal do colapso de predição documentado no Capítulo 5.

Tabela 3 – Comparação Etapa 3 (*embeddings*) vs Etapa 4 (sentimento FinBERT).

Modelo	AUC Etapa 3	AUC Etapa 4	Δ
BiLSTM Original	0,443	0,500	+0,057
BiLSTM Reduzido	0,505	0,477	−0,028
XGBoost	0,610	0,670	+0,060
Transformer	0,568	0,709	+0,141

(Nota: estes valores são pontuais, sem intervalos de confiança — esta omissão é uma das motivações para a investigação do Capítulo 5.)

O Transformer atinge ROC-AUC = 0,709 (acurácia 76,3%, 177 amostras). Porém, $precision(\text{Desce}) = 1,00$ com $recall(\text{Desce}) = 0,20$ — o modelo prevê “Desce” apenas 11 vezes em 177 amostras. Três observações motivam a investigação do Capítulo 5: (1) matriz de confusão assimétrica; (2) acurácia próxima da classe majoritária ($\sim 69\%$); (3) ausência de intervalos de confiança e múltiplas sementes.

5 Investigação Metodológica e o Viés da Avaliação por Janela Única

5.1 Motivação e protocolo geral

Este capítulo aplica protocolos progressivamente mais rigorosos para determinar se o AUC = 0,709 sobrevive a escrutínio metodológico. A Tabela 4 sumariza os 13 experimentos realizados (mais de 1.500 treinamentos).

Tabela 4 – Experimentos do Capítulo 5.

Experimento	Notebook	Runs
Baseline autoregressivo	<code>dumb_baseline.ipynb</code>	4
Baselines ingênuos	<code>naive_baselines.ipynb</code>	3
Controle de dimensionalidade	<code>dimensionality_control.ipynb</code>	20
Bootstrap CI (Etapa 4)	<code>bootstrap_stage4.ipynb</code>	1
Multi-seed em ITUB4	<code>multi_seed.ipynb</code>	40
Multi-seed × multi-ticker	<code>multi_seed_multi_ticker.ipynb</code>	120
Ensemble + backtest	<code>ensemble_backtest.ipynb</code>	20
Expanding-window CV	<code>expanding_window_cv.ipynb</code>	145
Varredura de horizontes	<code>horizon_sweep.ipynb</code>	6
VALE3 <i>deep-dive</i>	<code>vale3_deepdive.ipynb</code>	880
Ablation PRICE/SENT/PRICE+SENT	<code>ablation_price_vs_sentiment.ipynb</code>	225
Poder estatístico	<code>power_analysis.ipynb</code>	—
Validação TCN Stage 5b	<code>tcn_validation.ipynb</code>	45
Total		~1.510

Todos os hiperparâmetros dos modelos foram fixados ao longo dos experimentos, sem otimização por *fold*: XGBoost (300 árvores, profundidade 4, *learning rate* 0,05); Transformer (2 camadas, 4 cabeças, $d_{\text{model}} = 64$, *dropout* 0,2, 200 épocas com *early stopping* por perda de validação, paciência 10); TCN ([32,32], *kernel size* 3, *dropout* 0,2). A decisão de não otimizar hiperparâmetros por *fold* foi deliberada: o objetivo não era maximizar desempenho, mas medir a robustez do resultado original sob variação de janela e semente.

Respostas a questões metodológicas. O *early stopping* nos modelos neurais é baseado na perda de validação (não no AUC), com paciência de 10 épocas — o colapso bimodal não é um artefato de *early stopping*, pois ocorre independentemente do critério de parada. Os *folds* da CV *expanding-window* utilizam passo de 90 dias com janelas de teste de 90 dias, resultando em sobreposição parcial entre janelas de teste consecutivas; embora isto viole a independência estrita exigida pelo teste de Wilcoxon, o efeito é conservador (infla correlação, não produz significância espúria em resultados nulos). As 5 *features* de

sentimento FinBERT são normalizadas via `StandardScaler` fitado exclusivamente no conjunto de treino de cada *fold*. Por fim, a conclusão nula deve ser qualificada: dado o MDE de 0,132–0,221, efeitos reais menores que $\Delta\text{AUC} \approx 0,05$ seriam indetectáveis neste desenho experimental — o resultado é portanto “nenhum efeito detectável neste tamanho amostral”, não “nenhum efeito”.

5.2 Baseline autoregressivo e baselines ingênuos

Um XGBoost (CHEN; GUESTRIN, 2016) treinado em 5 *features* de preço (`return`, `lag_1`, `lag_5`, `Volume`, `std21`) atinge $\text{AUC} = 0,658$ [0,565; 0,744]. Para contextualizar, três preditores ingênuos foram avaliados:

Tabela 5 – Hierarquia de *baselines*: do ingênuo ao autoregressivo.

Preditor	Descrição	AUC [IC 95%]
Classe majoritária	Sempre prevê “Sobe”	0,500 [0,500; 0,500]
<i>Coin flip</i>	$P(\text{Sobe}) = \text{prior}$	0,500 [0,500; 0,500]
Persistência ($h = 21$)	Direção repete	0,474 [0,405; 0,543]
Autoregressivo (XGB)	5 features preço	0,658 [0,565; 0,744]

O controle de dimensionalidade (20 subconjuntos aleatórios de 5 dimensões Ollama) produz AUC médio de $0,509 \pm 0,057$, confirmando que a melhoria Etapa 3 $\rightarrow$ Etapa 4 reflete especificidade de domínio do FinBERT.

5.3 Reprodutibilidade e variância de semente

Sob recompilação com semente 42, o Transformer atinge $\text{AUC} = 0,442$ — diferença de 0,267 pontos ($22 \times$ o desvio-padrão do *baseline*). Sob 20 sementes (Tabela 6), o Transformer **exibe distribuição bimodal** (Figura 1).

Tabela 6 – Distribuição de AUC sobre 20 sementes (ITUB4, janela única).

Modelo	Média	Std	Mediana	Min	Max
Transformer + FinBERT	0,686	0,261	0,802	0,080	0,931
Baseline autoregressivo	0,641	0,012	0,638	0,615	0,660

5.4 Expanding-window cross-validation

Substituindo o *split* único por CV *expanding-window* (600 dias mínimo, validação/teste 90 dias, 5 *folds* $\times$ 5 sementes $\times$ 3 ativos = 145 treinamentos):




Figura 1 – Distribuição de AUC sobre 20 sementes em ITUB4. O Transformer (esquerda) exibe distribuição bimodal com AUCs agrupados próximos de 0 e 1, enquanto o *baseline* (direita) é estável em torno de 0,64. Coeficiente de variação do Transformer: 38%.

Tabela 7 – AUC médio sob *expanding-window* CV.

Ativo	Baseline XGB	Transformer	Δ
ITUB4	0,700	0,445	−0,255
PETR4	0,702	0,447	−0,255
VALE3	0,599	0,635	+0,036
Média	0,667	0,509	−0,158




Figura 2 – AUC por *fold* ao longo do tempo sob *expanding-window* CV, para os 3 ativos. A linha do *baseline* (vermelho) permanece consistentemente acima do Transformer (azul) em ITUB4 e PETR4, com barras de erro menores.

A inversão é de grande magnitude ($d \approx 6,25$, calculado como a diferença média de AUC entre modelos dividida pelo desvio-padrão do *baseline* ao longo dos *folds*: 0,25/0,04). A exceção aparente em VALE3 (+0,036) é investigada em *deep-dive* com 880 execuções e revelada como não significativa (Wilcoxon $p = 0,194$). A Figura 3 mostra a distribuição bimodal do Transformer em VALE3.

5.5 Ablation: o sentimento adiciona algo?

XGBoost em três configurações de *features* (225 treinamentos):




Figura 3 – Distribuição de 880 AUCs ($52 \text{ folds} \times 10 \text{ sementes}$) em VALE3. O *baseline* (esquerda) produz distribuição unimodal centrada em $\sim 0,55$. O Transformer (direita) produz distribuição bimodal severa com picos em $\text{AUC} < 0,05$ e $\text{AUC} > 0,95$ — assinatura de classificador degenerado.

Tabela 8 – Ablation: PRICE vs SENT vs PRICE+SENT.

Ativo	PRICE	SENT	PRICE+SENT	Δ
ITUB4	0,684	0,436	0,651	$-0,033$
PETR4	0,692	0,494	0,676	$-0,016$
VALE3	0,609	0,510	0,667	$+0,058$
Média	0,662	0,480	0,665	$+0,003$

O ganho do sentimento é $\Delta = +0,003$ (Wilcoxon $p = 0,49$, IC 95% $[-0,012; +0,018]$). A análise de poder (HANLEY; MCNEIL, 1982) confirma que este efeito está $44\text{--}74\times$ abaixo do MDE ($0,132\text{--}0,221$ para N entre 60 e 177).

5.6 Validação do TCN Stage 5b

O TCN [32,32] (BAI; KOLTER; KOLTUN, 2018) — melhor resultado prático ($\text{AUC} = 0,643$ sob janela única) — atinge $0,513 \pm 0,102$ sob 20 sementes e $0,556$ sob CV *expanding-window*, inferior ao *baseline* ($0,700$). A Figura 5 sumariza a validação.

5.7 Síntese

Sob avaliação metodologicamente correta (multi-fold, multi-sementes, com intervalos de confiança e *ablation* de *features*), as *features* de senti-




Figura 4 – Distribuição de AUC por configuração de *features* e ativo, sob *expanding-window* CV. PRICE e PRICE+SENT são estatisticamente indistinguíveis; SENT sozinho opera abaixo do acaso.




Figura 5 – Validação do TCN [32,32]. Esquerda: distribuição multi-seed (20 sementes) — 60% das sementes ficam abaixo de 0,50. Direita: distribuição *expanding-window* CV — AUC médio de 0,556, inferior ao *baseline*.

mento FinBERT-PT-BR não adicionam sinal preditivo mensurável a um *baseline* autoregressivo de cinco *features* de preço, em nenhum dos três ativos testados. O resultado original de AUC = 0,709 é um artefato da avaliação por janela única.

6 Conclusão

6.1 Contribuições

Este trabalho oferece três contribuições:

1. **Pipeline técnico replicável.** O sistema de coleta de notícias (InfoMoney), extração de sentimento (FinBERT-PT-BR) e integração com dados de mercado (Yahoo Finance) está integralmente versionado e pode ser reproduzido por outros pesquisadores.
2. **Demonstração empírica do viés de janela única.** A inversão de AUC 0,709 (janela única) para $\sim 0,51$ (multi-fold) é documentada com mais de 1.500 execuções e suporte estatístico formal. Esta é, no conhecimento do autor, a demonstração mais detalhada deste fenômeno em dados brasileiros.
3. **Proposição de protocolos mínimos.** O trabalho propõe seis práticas para pesquisa em ML financeiro: (1) reportar IC *bootstrap*; (2) treinar com ≥ 10 sementes; (3) usar CV *expanding-window*; (4) comparar contra *baseline* autoregressivo; (5) monitorar distribuição de predições; (6) auditar correlação validação-teste.

6.2 Reflexão sobre o processo de autocorreção

A experiência de construir um *pipeline* completo, obter um resultado aparentemente forte ($AUC = 0,709$) e depois desmontá-lo sistematicamente foi a lição mais valiosa deste trabalho. O viés de confirmação — a tendência natural de aceitar resultados que concordam com a hipótese — operou de forma invisível nas primeiras etapas: a ausência de intervalos de confiança, a fixação de uma única semente e o *split* único não pareciam problemáticos porque o resultado “fazia sentido”. A contribuição do Capítulo 5 não é a descoberta de que o sentimento não funciona — é a demonstração de quão fácil é produzir evidência aparente de que ele funciona, usando protocolos que a própria comunidade considera aceitáveis.

Os seis protocolos propostos na Seção anterior não são originais: o uso de múltiplas sementes, CV temporal e *baselines* autoregressivos são recomendações explícitas de Prado (2018). A contribuição deste trabalho é mostrar, em um caso concreto com dados brasileiros, a magnitude do dano causado por ignorá-los: uma inversão de 0,709 para $\sim 0,51$, que transforma uma conclusão positiva em negativa.

6.3 Limitações

As principais limitações incluem: (1) fonte única de notícias (InfoMoney), com viés editorial voltado ao investidor de varejo e cobertura heterogênea entre ativos (2.572 artigos para ITUB4 vs 1.525 para VALE3); (2) apenas 3 ações de grande capitalização da B3, limitando a validade externa; (3) horizonte de previsão restrito a 5 e 21 dias úteis; (4) a conclusão sobre o sentimento se aplica à representação específica adotada (5 *features* agregadas diariamente do FinBERT-PT-BR), não a toda forma possível de codificar informação textual; (5) a *ablation* (Seção 5.5) foi conduzida com $h = 21$, enquanto o TCN Stage 5b utiliza $h = 5$ — uma *ablation* com $h = 5$ fortaleceria a comparação.

6.4 Trabalhos futuros

Cinco direções são sugeridas: (1) diversificação de fontes textuais (comunicados CVM, *analyst reports*, redes sociais); (2) teste de arquiteturas menos propensas a colapso bimodal; (3) generalização para outros mercados; (4) estudo formal da anticorrelação validação-teste; (5) investigação de métricas ajustadas por desbalanceamento de classe (*balanced accuracy*, coeficiente de Matthews) como alternativa à AUC em conjuntos com *class imbalance* severo.

Referências

- ARACI, D. FinBERT: Financial sentiment analysis with pre-trained language models. *arXiv preprint arXiv:1908.10063*, 2019. Citado 2 vezes nas páginas 9 e 11.
- BAI, S.; KOLTER, J. Z.; KOLTUN, V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint arXiv:1803.01271*, 2018. Citado 2 vezes nas páginas 12 e 20.
- BAILEY, D. H. et al. Pseudo-mathematics and financial charlatanism: The effects of backtest overfitting on out-of-sample performance. *Notices of the American Mathematical Society*, v. 61, n. 5, p. 458–471, 2014. Citado 2 vezes nas páginas 10 e 12.
- CAVALCANTE, R. C. et al. Computational intelligence and financial markets: A survey and future directions. *Expert Systems with Applications*, v. 55, p. 194–211, 2016. Survey incluindo aplicações ao mercado brasileiro. Citado na página 12.
- CAWLEY, G. C.; TALBOT, N. L. C. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, v. 11, p. 2079–2107, 2010. Citado na página 12.
- CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.: s.n.], 2016. p. 785–794. Citado 2 vezes nas páginas 12 e 18.
- DEVLIN, J. et al. BERT: Pre-training of deep bidirectional transformers for language understanding. In: *Proceedings of the Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*. [S.l.: s.n.], 2019. p. 4171–4186. Citado na página 15.
- FAMA, E. F. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, v. 25, n. 2, p. 383–417, 1970. Citado 2 vezes nas páginas 9 e 11.
- FISCHER, T.; KRAUSS, C. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, v. 270, n. 2, p. 654–669, 2018. Citado na página 12.
- HANLEY, J. A.; MCNEIL, B. J. The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, v. 143, n. 1, p. 29–36, 1982. Citado 2 vezes nas páginas 12 e 20.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997. Citado na página 12.
- KELLY, B. T.; XIU, D. Financial machine learning. *Foundations and Trends in Finance*, v. 13, n. 3-4, p. 205–363, 2023. Citado na página 11.
- LO, A. W. The adaptive markets hypothesis. *Journal of Portfolio Management*, v. 30, n. 5, p. 15–29, 2004. Citado 2 vezes nas páginas 9 e 11.

- LOUGHRAN, T.; MCDONALD, B. When is a liability not a liability? textual analysis, dictionaries, and 10-ks. *The Journal of Finance*, v. 66, n. 1, p. 35–65, 2011. Citado na página 11.
- LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, v. 30, 2017. Citado na página 6.
- PRADO, M. López de. *Advances in Financial Machine Learning*. Hoboken: Wiley, 2018. Citado 3 vezes nas páginas 10, 12 e 22.
- SANTOS, L. F.; SILVA, N. F. F. *Análise de Sentimento em Textos Financeiros em Português com Modelos BERT*. Dissertação (Mestrado) — Universidade Federal de Goiás, 2020. Citado na página 12.
- SHAH, D.; ISAH, H.; ZULKERNINE, F. Stock market analysis: A review and taxonomy of prediction techniques. *International Journal of Financial Studies*, v. 7, n. 2, p. 26, 2019. Citado na página 11.
- SOUZA, G. C. B. d.; CARVALHO, R. L. G.; CALADO, A. d. A. FinBERT-PT-BR: Análise de sentimento de textos em português do mercado financeiro. *Anais do Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana (STIL)*, 2023. Citado 4 vezes nas páginas 2, 9, 11 e 15.
- VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2017. v. 30. Citado 2 vezes nas páginas 2 e 12.
- XU, Y.; COHEN, S. B. Stock movement prediction from tweets and historical prices. In: *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*. [S.l.: s.n.], 2018. p. 1970–1979. Citado 2 vezes nas páginas 9 e 12.

APÊNDICE A – Funções utilitárias de avaliação

O módulo `eval_utils.py` concentra as funções reutilizadas por todos os experimentos do Capítulo 5. As funções principais são reproduzidas abaixo.

Listing A.1 – Intervalo de confiança *bootstrap* para ROC-AUC.

```

1 def bootstrap_auc_ci(y_true, y_score, n_boot=1000,
2                       alpha=0.05, seed=42):
3     rng = np.random.default_rng(seed)
4     n = len(y_true)
5     aucs = np.empty(n_boot)
6     for i in range(n_boot):
7         idx = rng.integers(0, n, size=n)
8         if len(np.unique(y_true[idx])) < 2:
9             aucs[i] = np.nan
10            continue
11        aucs[i] = roc_auc_score(y_true[idx], y_score[idx])
12    aucs = aucs[~np.isnan(aucs)]
13    auc_point = roc_auc_score(y_true, y_score)
14    lower = float(np.quantile(aucs, alpha / 2))
15    upper = float(np.quantile(aucs, 1 - alpha / 2))
16    return float(auc_point), lower, upper

```

Listing A.2 – Split temporal walk-forward 70/15/15.

```

1 def walk_forward_split(df, train_frac=0.70,
2                        val_frac=0.15):
3     n = len(df)
4     n_train = int(n * train_frac)
5     n_val = int(n * val_frac)
6     train = df.iloc[:n_train]
7     val = df.iloc[n_train:n_train + n_val]
8     test = df.iloc[n_train + n_val:]
9     return train, val, test

```

APÊNDICE B – Arquitetura TCN

A TCN (*Temporal Convolutional Network*) utiliza blocos de convolução causal dilatada com conexões residuais. A configuração TCN [32,32] contém duas camadas com 32 filtros cada, *kernel size* 3 e dilatações [1,2].

Listing B.1 – Bloco convolucional causal da TCN.

```

1 class CausalConv1dBlock(nn.Module):
2     def __init__(self, in_ch, out_ch, kernel_size,
3                 dilation, dropout=0.2):
4         super().__init__()
5         padding = (kernel_size - 1) * dilation
6         self.conv1 = nn.Conv1d(in_ch, out_ch,
7                                kernel_size, padding=padding,
8                                dilation=dilation)
9         self.conv2 = nn.Conv1d(out_ch, out_ch,
10                                kernel_size, padding=padding,
11                                dilation=dilation)
12         self.chomp = padding
13         self.relu = nn.ReLU()
14         self.dropout = nn.Dropout(dropout)
15         self.downsample = (nn.Conv1d(in_ch, out_ch, 1)
16                             if in_ch != out_ch else None)
17
18     def forward(self, x):
19         out = self.dropout(self.relu(
20             self.conv1(x)[: , : , :-self.chomp]))
21         out = self.dropout(self.relu(
22             self.conv2(out)[: , : , :-self.chomp]))
23         res = (self.downsample(x)
24               if self.downsample else x)
25         return self.relu(out + res)

```