

Predição de Direção de Preços de Ações Brasileiras com Sentimento de Notícias Financeiras

Pipeline, Ilusão e Autocorreção Metodológica

André Takeo Loschner Fujiwara

Orientador: Prof. Eric Bacconi Gonçalves

Ciência de Dados e Inteligência Artificial — PUC-SP

Junho de 2026

- 1 Contexto e pergunta de pesquisa
- 2 Pipeline: notícias + dados de mercado
- 3 Resultado inicial: $AUC = 0,709$
- 4 Investigação metodológica (1.435 execuções)
- 5 Reversão da conclusão e protocolos propostos

Mensagem central

Um resultado positivo obtido sob protocolo padrão da literatura **não sobreviveu** à avaliação rigorosa — e documentar essa reversão é a contribuição principal.

Contexto e motivação

- ▶ Notícias financeiras como *features* preditivas: linha ativa em NLP + finanças (Xu & Cohen, 2018; Araci, 2019)
- ▶ Resultados positivos concentrados em mercados desenvolvidos (S&P 500)
- ▶ **B3 é estruturalmente diferente:** menor liquidez, poucas fontes jornalísticas especializadas, menos participantes institucionais
- ▶ NLP financeiro em português é recente: FinBERT-PT-BR disponível só a partir de 2022 (Souza et al., 2023)

Lacuna

Pouca evidência empírica para o mercado brasileiro — e quase nenhuma com avaliação metodologicamente rigorosa.

Notícias financeiras brasileiras melhoram a predição de direção de preço (sobe/desce) de ações da B3?

(a) Representação textual

Embeddings genéricos de 1.024 dimensões **ou** sentimento financeiro de 5 dimensões (FinBERT-PT-BR)?

(b) Robustez metodológica

Resultados de *walk-forward split* único sobrevivem a CV *expanding-window*, múltiplas sementes e testes formais?

Estudo de caso: **ITUB4**, **PETR4**, **VALE3** — horizontes $h = 5$ e $h = 21$ dias úteis.

Dados: notícias + mercado

Corpus de notícias (InfoMoney)

Ativo	Artigos	Período
ITUB4 (Itaú)	2.572	2009–2026
PETR4 (Petrobras)	1.775	2009–2026
VALE3 (Vale)	1.525	2009–2026
Total	5.872	

REST API do WordPress, retentativas com *backoff*, extração paralela.


Dados de mercado (Yahoo Finance)

- ▶ OHLCV diário por ativo
- ▶ 11 *features* técnicas: retorno, médias móveis (7/21), volatilidade (std 21), *lags*

Alvo binário

- ▶ 1 se $\text{Close}[t + h] > \text{Close}[t]$
- ▶ Desbalanceamento: 59% “Sobe” / 41% “Desce”

Pipeline



- Dataset final: ~1.200 dias úteis por ativo; janelas de 30 dias para modelos sequenciais
- **Risco conhecido:** *forward-fill* de sentimento em dias sem notícia (discutido na análise)

Etapa 3 — *embeddings* genéricos: perto do acaso

- ▶ Ollama qwen3-embedding:4b: 1.024 dimensões por artigo, média diária
- ▶ PCA → 32 componentes (61,4% da variância), ajustado só no treino
- ▶ 1.227 dias $\times$ 1.035 *features*

Leitura

Representação genérica de alta dimensionalidade carrega ruído semântico irrelevante ao domínio financeiro.

ROC-AUC, janela única, $h = 21$

Modelo	AUC
BiLSTM Original	0,443
BiLSTM Reduzido	0,505
Transformer	0,568
XGBoost	0,610

Etapa 4 — sentimento específico: FinBERT-PT-BR

O modelo

- ▶ BERT com *fine-tuning* em corpora financeiros em português (Souza et al., 2023)
- ▶ Calibrado para vocabulário do domínio: “alavancagem”, “*guidance*”, “*rating*”
- ▶ 3 *logits* por artigo: POSITIVO / NEGATIVO / NEUTRO

5 *features* diárias

- ▶ `n_articles`
- ▶ `mean_logit_pos / neg / neu`
- ▶ `mean_sentiment`

Hipótese

Representação compacta e específica ao domínio é mais informativa do que 1.024 dimensões genéricas.

O resultado que “confirmou” a hipótese

Etapa 3 (embeddings) vs Etapa 4 (FinBERT)

Modelo	E3	E4	Δ
BiLSTM Orig.	0,443	0,500	+0,057
BiLSTM Red.	0,505	0,477	−0,028
XGBoost	0,610	0,670	+0,060
Transformer	0,568	0,709	+0,141

- ▶ Transformer + FinBERT: ROC-AUC = **0,709**, acurácia 76,3%
- ▶ Narrativa coerente: “sentimento específico supera *embeddings* genéricos”
- ▶ Resultado compatível com a literatura internacional

Caso encerrado? **Não.**

Três sinais de alerta

- ❶ **Matriz de confusão assimétrica:** $\text{precision}(\text{Desce}) = 1,00$ com $\text{recall}(\text{Desce}) = 0,15$ — o modelo previu “Desce” apenas **11 vezes em 177 amostras**
- ❷ **Acurácia suspeita:** 76,3% próxima da classe majoritária ($\sim 69\%$ “Sobe”)
- ❸ **Protocolo frágil:** estimativa pontual — **sem** intervalo de confiança, **uma** semente, **uma** janela temporal

Decisão

Antes de aceitar o resultado: submetê-lo a protocolos progressivamente mais rigorosos. Se for real, sobrevive.

Investigação metodológica: 8 experimentos, 1.435 execuções

Experimento	Runs
Baseline autoregressivo	4
Bootstrap CI	1
Multi-seed (ITUB4)	40
Multi-seed $\times$ multi-ticker	120
Ensemble + backtest	20
Expanding-window CV	145
VALE3 <i>deep-dive</i>	880
Ablation PRICE/SENT/PRICE+SENT	225
Total	1.435

Regras fixas em todos os experimentos


- ▶ Hiperparâmetros congelados (sem otimização por *fold*)
- ▶ StandardScaler ajustado só no treino de cada *fold*
- ▶ Bootstrap CI com 1.000 reamostras
- ▶ Teste de Wilcoxon para comparações pareadas

Primeiro confronto: hierarquia de *baselines*

Preditor	Descrição	AUC [IC 95%]
Classe majoritária	Sempre prevê “Sobe”	0,500
<i>Coin flip</i>	$P(\text{Sobe}) = \text{prior}$	0,500
Persistência ($h = 21$)	Direção repete	0,474 [0,405; 0,543]
Autoregressivo (XGB)	5 <i>features</i> de preço	0,658 [0,565; 0,744]

- ▶ XGBoost com só return, lag_1, lag_5, Volume, std21 já atinge **0,658**
- ▶ O IC do *baseline* já engloba o 0,709 do Transformer + FinBERT
- ▶ Controle de dimensionalidade (20 subconjuntos aleatórios de 5 dims Ollama): AUC $0,509 \pm 0,057$


Multi-seed: o colapso bimodal



Como ler: cada barra = 1 semente. **Azul** (meu modelo) espalhado de 0,08 a 0,93; **vermelho** (baseline) apertado em $\sim 0,65$. A linha do 0,709 cai na **ponta direita** $\Rightarrow$ semente sortuda.

- Semente 42: AUC cai de 0,709 para **0,442** — só trocando o sorteio
- 20 sementes: Transformer std = **0,261** ($21 \times$ o *baseline*, que tem std 0,012)
- **Bimodal**: acumula nas pontas $\Rightarrow$ colapso para “sempre Sobe” ou “sempre Desce”

Expanding-window CV: a inversão




Como ler: 3 ativos, eixo X = tempo (folds). **Vermelho** = preço, **azul** = meu modelo. Em ITUB4 e PETR4 o **vermelho fica por cima** $\Rightarrow$ o preço ganha.

AUC médio (5 folds $\times$ 5 sementes)

Ativo	XGB	Transf.	Δ
ITUB4	0,700	0,445	-0,255
PETR4	0,702	0,447	-0,255
VALE3	0,599	0,635	+0,036
Média	0,667	0,509	-0,158

- Trocando 1 janela por 5 folds: **o resultado inverte**
- Diferença de 0,255 em ITUB4 $\approx 6\times$ o desvio do *baseline*


E a exceção VALE3? *Deep-dive* com 880 execuções



- ▶ Era o único ativo com ganho aparente (+0,036) na análise principal
- ▶ Reforço: **52 folds** × **10 sementes** = 880 execuções
- ▶ Resultado: **não significativo** (Wilcoxon $p = 0,194$) — a exceção morreu

Como ler: 880 execuções. **Azul** (meu modelo) acumula nas **duas pontas** (perto de 0 e de 1) = colapso. A média azul (0,484) fica à **esquerda** da **vermelha** (0,544) $\Rightarrow$ perde até aqui.

Ablation: o sentimento adiciona algo ao preço?



Como ler: 3 caixas por ativo. Verde (só sentimento) fica **na linha do acaso ou abaixo**. Vermelho (preço) $\approx$ azul (preço+sent.) $\Rightarrow$ somar sentimento quase não move nada.

XGBoost, 225 treinamentos, $h = 21$

Ativo	PRICE	SENT	P+S	Δ
ITUB4	0,684	0,436	0,651	-0,033
PETR4	0,692	0,494	0,676	-0,016
VALE3	0,609	0,510	0,667	+0,058
Média	0,662	0,480	0,665	+0,003

- $\Delta = +0,003$; Wilcoxon $p = 0,49$; IC 95% $[-0,012; +0,018]$
- SENT sozinho: **abaixo do acaso**
- Efeito 44–74 $\times$ menor que o mínimo detectável (MDE 0,13–0,22)

Síntese da investigação

Conclusão unificada

Sob avaliação correta (multi-*fold*, multi-semente, IC, *ablation*), as *features* de sentimento FinBERT-PT-BR **não adicionam sinal preditivo mensurável** ao *baseline* autoregressivo — em nenhum dos três ativos.

O AUC de 0,709 era um artefato de janela única, produzido por:

- ❶ Variância de semente (std 0,261 — colapso bimodal do Transformer)
- ❷ Viés de amostragem da janela de teste específica
- ❸ Ausência de intervalos de confiança que revelariam a incerteza

Escopo: conclusão vale para a representação adotada (5 *features* diárias FinBERT-PT-BR), não para toda forma de incorporar texto. Resultado é “nenhum efeito detectável neste tamanho amostral”.

Contribuições e protocolos mínimos propostos

Três contribuições

- 1 Pipeline replicável e versionado (InfoMoney + FinBERT-PT-BR + Yahoo Finance)
- 2 Primeira demonstração quantificada do viés de janela única em dados brasileiros (1.435 execuções)
- 3 Proposição de protocolos mínimos para ML financeiro

Práticas alinhadas a López de Prado (2018); a contribuição é mostrar, em caso concreto, a magnitude do dano de ignorá-las.

Seis práticas mínimas

- 1 Reportar IC *bootstrap*
- 2 Treinar com ≥ 10 sementes
- 3 CV *expanding-window*
- 4 Comparar contra *baseline* autoregressivo
- 5 Monitorar distribuição de predições
- 6 Auditar correlação validação-teste

Limitações e trabalhos futuros

Limitações

- ▶ Fonte única (InfoMoney, viés varejo)
- ▶ 3 ativos de grande capitalização
- ▶ Horizontes restritos ($h = 5$, $h = 21$)
- ▶ Representação textual específica (5 *features* agregadas)
- ▶ *Look-ahead* residual do *forward-fill* — mas joga *contra* a conclusão nula
- ▶ Instabilidade arquitetural do Transformer

Trabalhos futuros

- ▶ Diversificar fontes (CVM, *analyst reports*, redes sociais)
- ▶ Arquiteturas menos propensas a colapso bimodal
- ▶ Outros mercados emergentes
- ▶ Estudo formal da anticorrelação validação-teste
- ▶ Métricas robustas a desbalanceamento (*balanced accuracy*, MCC)

Mensagem final

A contribuição central não é descobrir que o sentimento não funciona — é demonstrar **quão fácil é produzir evidência aparente de que funciona**, usando protocolos que a comunidade considera aceitáveis.

- ▶ Viés de confirmação opera de forma invisível: o 0,709 “fazia sentido”
- ▶ Janela única + semente única + ausência de IC: receita para falso positivo
- ▶ Autocorreção documentada > resultado positivo frágil

Obrigado!

André Takeo Loschner Fujiwara — Ciência de Dados e IA, PUC-SP
Código e dados: repositório versionado do projeto