

André Takeo Loschner Fujiwara

**Predição de Direção de Preços de Ações
Brasileiras
com Sentimento de Notícias Financeiras:
Pipeline, Ilusão e Autocorreção Metodológica**

São Paulo

2026

André Takeo Loschner Fujiwara

**Predição de Direção de Preços de Ações Brasileiras
com Sentimento de Notícias Financeiras:
Pipeline, Ilusão e Autocorreção Metodológica**

Trabalho de Conclusão de Curso apresentado
ao Curso de Ciência de Dados e Inteligência
Artificial da PUC-SP como requisito parcial
para a obtenção do grau de Bacharel.

PUC-SP

Curso de Ciência de Dados e Inteligência Artificial

Orientador: Prof. Eric Bacconi Gonçalves

São Paulo
2026

Resumo

A predição de direção de preços em mercados financeiros emergentes por meio de análise de sentimento em notícias permanece um problema em aberto, especialmente no contexto brasileiro, onde modelos de linguagem específicos para o domínio financeiro em português são escassos. Este trabalho investiga se notícias financeiras brasileiras melhoram a predição de direção de preços de ações da B3, tomando como estudo de caso três ações de grande capitalização — ITUB4 (Itaú Unibanco), PETR4 (Petrobras) e VALE3 (Vale). O *pipeline* proposto coleta artigos do portal InfoMoney, extrai representações de sentimento via FinBERT-PT-BR — um modelo BERT especializado em textos financeiros em português (SOUZA; CARVALHO; CALADO, 2023) — e combina as *features* resultantes com dados de mercado do Yahoo Finance para treinar classificadores binários (sobe/desce).

A principal contribuição deste trabalho é uma autocorreção metodológica documentada: uma conclusão inicialmente positiva é revertida pela própria investigação após ampliação rigorosa do protocolo de avaliação. Sob avaliação por janela única (*walk-forward split* 70/15/15), o modelo Transformer (VASWANI et al., 2017) atinge ROC-AUC de 0,709 — resultado que aparenta demonstrar que sentimento financeiro específico ao domínio supera *embeddings* genéricos de alta dimensionalidade. Uma investigação sistemática com mais de 1.500 execuções de modelo revela, porém, que esse valor é um artefato de janela única: o Transformer exhibe colapso bimodal (AUC oscilando entre 0,08 e 0,93 conforme a semente aleatória), e sob avaliação *multi-fold* o sentimento adiciona $\Delta = +0,003$ ao *baseline* autoregressivo (Wilcoxon *signed-rank* $p = 0,49$, IC 95% *bootstrap* $[-0,012; +0,018]$) — revertendo a conclusão qualitativa de positiva para nula.

A reversão é demonstrada empiricamente em dados brasileiros e sustentada por seis protocolos de avaliação complementares: intervalos de confiança *bootstrap* (1.000 reamostras), análise *multi-seed* com no mínimo 10 sementes, validação cruzada *expanding-window* (até 52 *folds*), *baseline* autoregressivo como referência mínima, monitoramento da distribuição de predições e auditoria de correlação entre validação e teste. Esses protocolos são propostos como conjunto mínimo para mitigar o viés de janela única em estudos de *machine learning* financeiro.

Palavras-chave: Predição de preços. Sentimento financeiro. FinBERT. Avaliação metodológica. Séries temporais financeiras. B3.

Abstract

Predicting stock price direction in emerging financial markets using news sentiment analysis remains an open problem, particularly in the Brazilian context where domain-specific language models for Portuguese financial text are scarce. This work investigates whether Brazilian financial news improves stock price direction prediction for B3 equities, using three large-cap stocks as case studies: ITUB4 (Itaú Unibanco), PETR4 (Petrobras), and VALE3 (Vale). The proposed pipeline collects articles from the InfoMoney portal, extracts sentiment representations via FinBERT-PT-BR — a BERT model fine-tuned on Brazilian Portuguese financial text (SOUZA; CARVALHO; CALADO, 2023) — and combines the resulting features with Yahoo Finance market data to train binary classifiers (up/down). The primary contribution of this work is a documented methodological self-correction: an initially positive conclusion is reversed by the same investigation after rigorous expansion of the evaluation protocol. Under single-window evaluation (70/15/15 walk-forward split), the Transformer model (VASWANI et al., 2017) achieves ROC-AUC of 0.709 — a result that apparently demonstrates domain-specific financial sentiment outperforming high-dimensional generic embeddings. A systematic investigation comprising over 1,500 model runs reveals this value to be a single-window artifact: the Transformer exhibits bimodal collapse (AUC ranging from 0.08 to 0.93 depending on random seed), and under multi-fold evaluation sentiment adds $\Delta = +0.003$ over the autoregressive baseline (Wilcoxon signed-rank $p = 0.49$, 95% bootstrap CI $[-0.012, +0.018]$) — reversing the qualitative conclusion from positive to null.

This reversal is empirically demonstrated on Brazilian data and supported by six complementary evaluation protocols: bootstrap confidence intervals (1,000 resamples), multi-seed analysis with at least 10 seeds, expanding-window cross-validation (up to 52 folds), an autoregressive baseline as minimum reference, prediction distribution monitoring, and validation-test correlation auditing. These protocols are proposed as a minimum checklist to mitigate single-window bias in financial machine learning studies.

Keywords: Price prediction. Financial sentiment. FinBERT. Methodological evaluation. Financial time series. B3.

Lista de ilustrações

- Figura 1 – Distribuição de AUC sobre 20 sementes em ITUB4. O Transformer (esquerda) exibe distribuição bimodal com AUCs agrupados próximos de 0 e 1, enquanto o *baseline* (direita) é estável em torno de 0,64. Coeficiente de variação do Transformer: 38%. 22
- Figura 2 – AUC por *fold* ao longo do tempo sob *expanding-window* CV, para os 3 ativos. A linha do *baseline* (vermelho) permanece consistentemente acima do Transformer (azul) em ITUB4 e PETR4, com barras de erro menores. As barras de erro representam o desvio-padrão do AUC entre as 5 sementes por *fold*. 23
- Figura 3 – Distribuição de 880 AUCs ($52 \text{ folds} \times 10 \text{ sementes}$) em VALE3. O *baseline* (esquerda) produz distribuição unimodal centrada em $\sim 0,55$. O Transformer (direita) produz distribuição bimodal severa com picos em $\text{AUC} < 0,05$ e $\text{AUC} > 0,95$ — assinatura de classificador degenerado — padrão característico de um modelo que colapsa para predição constante independentemente da entrada. 24
- Figura 4 – Distribuição de AUC por configuração de *features* e ativo, sob *expanding-window* CV. PRICE e PRICE+SENT são estatisticamente indistinguíveis; SENT sozinho opera abaixo do acaso. 25
- Figura 5 – Validação do TCN [32,32]. Esquerda: distribuição multi-seed (20 sementes) — 60% das sementes ficam abaixo de 0,50. Direita: distribuição *expanding-window* CV — AUC médio de 0,556, inferior ao *baseline*. . . 25

Lista de tabelas

Tabela 1	– Volume de artigos coletados por ativo.	16
Tabela 2	– Resultados com <i>embeddings</i> genéricos Ollama (Etapa 3). Nota: estimativas pontuais de uma única semente e uma única janela temporal, reportadas para continuidade narrativa; o Capítulo 5 aplica avaliação multi-semente e multi- <i>fold</i> aos resultados da Etapa 4.	17
Tabela 3	– Comparação Etapa 3 (<i>embeddings</i>) vs Etapa 4 (sentimento FinBERT). Nota: todos os valores são estimativas pontuais de uma única semente e uma única janela temporal, sem intervalos de confiança — esta omissão é uma das motivações para a investigação do Capítulo 5.	19
Tabela 4	– Experimentos do Capítulo 5.	20
Tabela 5	– Hierarquia de <i>baselines</i> : do ingênuo ao autoregressivo.	21
Tabela 6	– Distribuição de AUC sobre 20 sementes (ITUB4, janela única).	22
Tabela 7	– AUC médio sob <i>expanding-window</i> CV.	23
Tabela 8	– Ablation: PRICE vs SENT vs PRICE+SENT. $\Delta = \text{PRICE+SENT} - \text{PRICE}$	24

Lista de abreviaturas e siglas

AUC	<i>Area Under the ROC Curve</i>
B3	Brasil, Bolsa, Balcão
BERT	<i>Bidirectional Encoder Representations from Transformers</i>
BiLSTM	<i>Bidirectional Long Short-Term Memory</i>
CI	Intervalo de Confiança (<i>Confidence Interval</i>)
CV	Validação Cruzada (<i>Cross-Validation</i>)
FinBERT	<i>Financial BERT</i>
LSTM	<i>Long Short-Term Memory</i>
MDE	Tamanho Mínimo de Efeito Detectável
NLP	Processamento de Linguagem Natural
OHLCV	<i>Open, High, Low, Close, Volume</i>
PCA	Análise de Componentes Principais
ROC	<i>Receiver Operating Characteristic</i>
SHAP	<i>SHapley Additive exPlanations</i> (LUNDBERG; LEE, 2017)
TCN	<i>Temporal Convolutional Network</i>
XGB	XGBoost (<i>eXtreme Gradient Boosting</i>)

Sumário

1	INTRODUÇÃO	9
1.1	Problema de pesquisa	9
1.2	Objetivos	10
1.2.1	Objetivo geral	10
1.2.2	Objetivos específicos	10
1.3	Justificativa	10
1.4	Estrutura do trabalho	11
2	REVISÃO BIBLIOGRÁFICA	12
2.1	Hipótese de eficiência de mercado	12
2.2	NLP aplicado a finanças	12
2.3	Arquiteturas de modelos	13
2.4	Protocolos de avaliação em ML financeiro	14
3	PIPELINE: COLETA, ENGENHARIA DE FEATURES E MODELOS INICIAIS	16
3.1	Coleta de notícias financeiras	16
3.2	Engenharia de features	16
3.3	Modelos iniciais com embeddings genéricos	17
4	SENTIMENTO FINANCEIRO ESPECÍFICO VIA FINBERT-PT-BR	18
4.1	Hipótese	18
4.2	O modelo FinBERT-PT-BR	18
4.3	Pipeline de extração e resultados	18
5	INVESTIGAÇÃO METODOLÓGICA E O VIÉS DA AVALIAÇÃO POR JANELA ÚNICA	20
5.1	Motivação e protocolo geral	20
5.2	Baseline autoregressivo e baselines ingênuos	21
5.3	Reprodutibilidade e variância de semente	22
5.4	Expanding-window cross-validation	22
5.5	Ablation: o sentimento adiciona algo?	23
5.6	Validação do TCN Stage 5b	24
5.7	Síntese	24
6	CONCLUSÃO	27
6.1	Contribuições	27

6.2	Reflexão sobre o processo de autocorreção	27
6.3	Limitações	28
6.4	Trabalhos futuros	28
	REFERÊNCIAS	29
	APÊNDICE A – FUNÇÕES UTILITÁRIAS DE AVALIAÇÃO	31
	APÊNDICE B – ARQUITETURA TCN	32

1 Introdução

A predição de direção de preços de ações é um problema central em finanças quantitativas, situado na interseção entre a hipótese de eficiência de mercado (FAMA, 1970) e a evidência empírica de previsibilidade parcial em horizontes curtos (LO, 2004). Com o avanço das técnicas de processamento de linguagem natural (NLP), uma linha de pesquisa crescente investiga se informações textuais — notícias, relatórios de analistas, publicações em redes sociais — podem ser incorporadas como *features* preditivas em modelos de *machine learning* para complementar dados tradicionais de preço e volume (XU; COHEN, 2018; ARACI, 2019).

No contexto brasileiro, a pesquisa nesta área é ainda incipiente. A B3 (Brasil, Bolsa, Balcão) apresenta características que a distinguem de mercados desenvolvidos: menor liquidez em ações fora do índice principal, concentração de informação em poucas fontes jornalísticas especializadas, e um ecossistema de NLP em português que, a partir de 2022, passou a dispor de modelos de linguagem específicos para o domínio financeiro, como o FinBERT-PT-BR (SOUZA; CARVALHO; CALADO, 2023). Essas diferenças estruturais implicam que resultados positivos obtidos em mercados como o S&P 500 (XU; COHEN, 2018; FISCHER; KRAUSS, 2018) não podem ser diretamente extrapolados para a B3: o fluxo informacional é mais concentrado, o *pool* de participantes institucionais é menor do que em mercados desenvolvidos como os EUA, e os modelos de linguagem disponíveis em português financeiro têm histórico de avaliação significativamente mais curto do que seus equivalentes em inglês.

1.1 Problema de pesquisa

O problema central pode ser formulado como: **notícias financeiras brasileiras melhoram a predição de direção de preço (sobe/desce) de ações da B3?** Esta questão desdobra-se em duas dimensões:

- (a) **Representação textual:** qual forma de codificar o conteúdo de notícias — *embeddings* genéricos de alta dimensionalidade ou sentimento financeiro específico de baixa dimensionalidade — produz *features* mais informativas para a predição?
- (b) **Robustez metodológica:** os resultados obtidos sob protocolos de avaliação padrão da literatura (*walk-forward split* único) sobrevivem a escrutínio com validação cruzada *expanding-window*, múltiplas sementes e testes estatísticos formais?

1.2 Objetivos

1.2.1 Objetivo geral

Investigar empiricamente se *features* de sentimento extraídas de notícias financeiras brasileiras adicionam poder preditivo a modelos de classificação binária de direção de preço de ações da B3, sob avaliação metodologicamente rigorosa.

1.2.2 Objetivos específicos

1. Construir um *pipeline* de coleta, processamento e integração de notícias financeiras do portal InfoMoney com dados de mercado do Yahoo Finance.
2. Comparar duas estratégias de representação textual: *embeddings* genéricos de 1.024 dimensões (Ollama `qwen3-embedding:4b`) e sentimento financeiro de 5 dimensões (FinBERT-PT-BR).
3. Treinar e avaliar modelos de classificação binária (BiLSTM, Transformer, XGBoost, TCN — *Temporal Convolutional Network*) sobre as representações textuais combinadas com *features* de preço.
4. Aplicar protocolos de avaliação rigorosa — *bootstrap* CI, análise *multi-seed*, validação cruzada *expanding-window*, *ablation* de *features* — para determinar a robustez dos resultados.
5. Documentar e analisar as discrepâncias entre avaliação por janela única e avaliação multi-fold, contribuindo para a literatura de avaliação metodológica em ML financeiro.

1.3 Justificativa

A relevância deste trabalho reside em três aspectos. Primeiro, a aplicação de NLP financeiro ao mercado brasileiro é pouco explorada, e a disponibilidade recente de modelos como o FinBERT-PT-BR abre oportunidades de investigação em português. Segundo, a literatura de *deep learning* aplicado a finanças sofre de um problema metodológico amplamente documentado — a avaliação por janela única em séries não-estacionárias (BAILEY et al., 2014; PRADO, 2018) — mas raramente demonstrado empiricamente com o grau de detalhe que este trabalho propõe. Terceiro, a autocorreção metodológica documentada nos Capítulos 4 e 5 constitui, por si só, uma contribuição pedagógica. Especificamente, este trabalho demonstra empiricamente as três armadilhas mais comuns na avaliação de modelos em ML financeiro: ausência de intervalos de confiança, uso de semente única, e avaliação por janela única em séries não-estacionárias.

1.4 Estrutura do trabalho

O trabalho está organizado em seis capítulos. O presente capítulo introduz o problema de pesquisa, os objetivos e a justificativa. O Capítulo 2 apresenta a fundamentação teórica e a revisão bibliográfica. O Capítulo 3 descreve o *pipeline* completo: coleta de notícias, engenharia de *features* e treinamento inicial com *embeddings* genéricos. O Capítulo 4 introduz o FinBERT-PT-BR e documenta o resultado inicialmente promissor (*Area Under the ROC Curve*, $AUC = 0,709$). O Capítulo 5 conduz a investigação metodológica que revisa substancialmente esse resultado. O Capítulo 6 sintetiza as conclusões e propõe direções futuras.

2 Revisão Bibliográfica

Este capítulo apresenta os fundamentos teóricos que sustentam o trabalho: a hipótese de eficiência de mercado e suas implicações para a previsibilidade de preços, o uso de NLP em finanças, e os protocolos de avaliação em *machine learning* para séries temporais financeiras.

2.1 Hipótese de eficiência de mercado

A hipótese de eficiência de mercado (HEM), formalizada por Fama (1970), postula que os preços dos ativos refletem toda a informação disponível. Em sua forma semiforte, a HEM implica que informações públicas — incluindo notícias financeiras — já estão incorporadas nos preços no momento de sua publicação, tornando impossível obter retornos sistematicamente superiores com base nessas informações. Trabalhos empíricos subsequentes, contudo, documentaram anomalias que sugerem previsibilidade parcial. Lo (2004) propôs a Hipótese de Mercados Adaptativos, na qual a eficiência varia ao longo do tempo conforme as condições de mercado e o comportamento dos agentes.

Este trabalho parte dessa tensão como ponto de partida empírico: se os preços já incorporam o sentimento das notícias financeiras, um modelo treinado sobre esse sentimento não deveria superar um *baseline* autoregressivo de preço (*baseline* autoregressivo: modelo que usa exclusivamente dados históricos de preço como *features*); se não incorporam completamente, há espaço mensurável para predição. O Capítulo 4 testa essa hipótese para ITUB4, PETR4 e VALE3 sob protocolo de janela única, obtendo o resultado dessa avaliação inicial — aparentemente favorável ao segundo cenário. O Capítulo 5 submete esse resultado a validação cruzada *expanding-window* com múltiplas sementes e testes de significância formal, revelando que o ganho sobre o *baseline* autoregressivo não é estatisticamente distinguível do acaso ($p = 0,49$, IC 95% $[-0,012; +0,018]$), revertendo a conclusão qualitativa de positiva para nula.

2.2 NLP aplicado a finanças

A aplicação de processamento de linguagem natural à predição de preços pode ser organizada em três gerações de representação textual (KELLY; XIU, 2023). A primeira utilizou léxicos de sentimento construídos manualmente, como o Loughran-McDonald (LOUGHRAN; MCDONALD, 2011), atribuindo polaridade a palavras individuais com base em dicionários específicos do domínio. A segunda introduziu *embeddings* densos baseados em redes neurais, como Word2Vec (MIKOLOV et al., 2013) e GloVe (PENNINGTON;

SOCHER; MANNING, 2014), que capturam relações semânticas distribuídas mas não são específicos ao domínio financeiro. A terceira geração, dominante desde o início da década de 2020, utiliza modelos de linguagem pré-treinados e *fine-tuned* para o domínio, como o FinBERT (ARACI, 2019) e suas variantes regionais, incluindo o FinBERT-PT-BR para português brasileiro (SOUZA; CARVALHO; CALADO, 2023).

É importante notar que resultados nulos ou negativos são sub-representados na literatura de NLP financeiro devido ao viés de publicação (SHAH; ISAH; ZULKERNINE, 2019). Shah, Isah e Zulkernine (2019) documentaram que muitos estudos de *sentiment analysis* para previsão de ações não replicam quando avaliados fora da amostra original. Kelly e Xiu (2023) mostraram que a maior parte do poder preditivo de variáveis textuais desaparece quando as variáveis textuais são combinadas com *features* de preço em modelos com controle explícito de dimensionalidade — resultado alinhado com os achados deste trabalho.

Xu e Cohen (2018) demonstraram que a combinação de texto de *tweets* com séries históricas de preço melhora a predição de direção em ações do S&P 500, utilizando um modelo de atenção hierárquico; seu modelo StockNet atinge acurácia de 58,2% e *Matthews correlation coefficient* (MCC) de 0,081 sobre 88 ativos norte-americanos de alto volume de negociação. Fischer e Krauss (2018) aplicaram LSTMs (*Long Short-Term Memory*, proposta originalmente por Hochreiter e Schmidhuber (1997)) à predição de retornos diários de ações do S&P 500, reportando retorno diário de 0,46% e índice de Sharpe de 5,8 (antes de custos de transação), superando o *buy-and-hold*; a acurácia direcional, porém, situa-se apenas marginalmente acima de 50%. Ding et al. (2015) combinaram *embeddings* de eventos extraídos de notícias com redes convolucionais, alcançando acurácia direcional de 64,2% na predição do índice S&P 500 e 65,5% na predição de ações individuais. Hu et al. (2018) propuseram um arcabouço de atenção hierárquica para tendências de ações chinesas orientado a notícias, reportando retorno anualizado de 61,1% para a carteira das 40 melhores ações (a acurácia de 47,8% não é diretamente comparável aos demais valores por se tratar de uma tarefa de três classes). No contexto brasileiro, a literatura é majoritariamente exploratória: Cavalcante et al. (2016) apresentam um levantamento abrangente de métodos de inteligência computacional aplicados a mercados financeiros, sem reportar uma métrica preditiva única. Nenhum desses estudos reporta análise de variância de semente ou validação cruzada com múltiplas janelas temporais — uma prática que, como demonstrado no Capítulo 5, pode reverter as conclusões qualitativas dos resultados.

2.3 Arquiteturas de modelos

Este trabalho utiliza quatro famílias de modelos, selecionadas por sua representatividade na literatura de ML financeiro. O BiLSTM — baseado no LSTM (HOCHREITER; SCHMIDHUBER, 1997), na extensão bidirecional proposta na literatura — nas variantes de 2

camadas/128 unidades e 1 camada/32 unidades — processa sequências temporais bidirecionalmente, sendo amplamente utilizado em previsão de preços (FISCHER; KRAUSS, 2018). O Transformer (VASWANI et al., 2017) — com encoder de 2 camadas, 4 cabeças de atenção e $d_{\text{model}} = 64$ — utiliza mecanismos de atenção *multi-head* que permitem capturar relações entre posições arbitrárias na sequência, sem viés de localidade. O XGBoost (CHEN; GUESTRIN, 2016) — 300 árvores, profundidade 4, *learning rate* 0,05 — é o padrão de facto para dados tabulares e serve como *baseline* autoregressivo nos experimentos do Capítulo 5. A TCN (*Temporal Convolutional Network*) (BAI; KOLTER; KOLTUN, 2018) — configuração [32,32], *kernel* 3, dilatações [1,2] — aplica convoluções dilatadas causais, capturando padrões temporais locais com campo receptivo exponencialmente crescente.

Modelos alternativos foram considerados mas não adotados como modelos principais: o Random Forest foi avaliado no Estágio 7 como diagnóstico adicional de importância de *features* via SHAP (*SHapley Additive exPlanations*) (LUNDBERG; LEE, 2017), mas não como modelo principal, pois o XGBoost oferece desempenho equivalente com maior controle de regularização e interpretabilidade nativa. A Regressão Logística com interações foi avaliada nos *baselines* ingênuos iniciais, mas suas premissas de linearidade são inadequadas para a dinâmica não-linear de séries financeiras em janelas de 30 dias. A GRU (*Gated Recurrent Unit*) foi preterida por redundância arquitetural com o BiLSTM neste contexto: ambas processam sequências com mecanismos de memória recorrente, e a literatura não evidencia ganhos sistemáticos de GRU sobre LSTM em séries financeiras de baixa frequência (FISCHER; KRAUSS, 2018).

2.4 Protocolos de avaliação em ML financeiro

A avaliação de modelos preditivos em séries temporais financeiras apresenta desafios específicos que a distinguem de problemas padrão de *machine learning*. Bailey et al. (2014) demonstraram formalmente que a otimização de estratégias sobre um único período de *backtest* inevitavelmente infla métricas de desempenho — o fenômeno que denominaram *backtest overfitting*. Prado (2018) sistematizou o problema, propondo validação cruzada com purga e embargo como padrão mínimo. Cawley e Talbot (2010) documentaram o viés de seleção de modelo, mostrando que a avaliação sobre o mesmo conjunto de dados usado para selecionar modelos produz estimativas otimistas mesmo sem vazamento explícito de dados.

A métrica ROC-AUC, embora amplamente utilizada, deve ser interpretada com cautela em conjuntos de teste pequenos. Hanley e McNeil (1982) derivaram o erro-padrão analítico da AUC, permitindo o cálculo de intervalos de confiança e tamanhos mínimos de efeito detectáveis — ferramenta essencial quando os conjuntos de teste têm 60–177 amostras, como neste trabalho.

A validação cruzada com janela expansiva (*expanding-window CV*) é a abordagem

recomendada por Prado (2018) para séries temporais financeiras: a cada *fold*, o conjunto de treino expande-se cronologicamente enquanto a janela de teste avança, simulando o processo de decisão em tempo real. Em contraste com o *walk-forward split* único, esta abordagem fornece múltiplas estimativas de desempenho fora da amostra, permitindo avaliar tanto o nível médio quanto a variância do desempenho ao longo do tempo.

3 Pipeline: Coleta, Engenharia de Features e Modelos Iniciais

Este capítulo descreve as três primeiras etapas do *pipeline*: coleta de notícias financeiras, engenharia de *features* (mercado e texto) e treinamento inicial de modelos com *embeddings* genéricos.

3.1 Coleta de notícias financeiras

O corpus textual foi construído a partir do portal InfoMoney, uma das principais fontes de notícias financeiras no Brasil. O módulo `extractor.py` acessa a REST API do WordPress do portal (`/wp-json/wp/v2/posts`), realizando buscas paginadas (100 artigos por página) para cada *ticker* analisado. Cada requisição HTTP possui mecanismo de retentativa: até 3 tentativas com *backoff* linear (1 s, 2 s), tratando erros de *timeout*, conexão e códigos de status 429/5xx. Os artigos passam por pré-processamento (remoção de *tags* HTML, decodificação de entidades, normalização de *whitespace*) e a extração ocorre em paralelo via `ThreadPoolExecutor`.

Tabela 1 – Volume de artigos coletados por ativo.

Ativo	Artigos	Período
ITUB4 (Itaú Unibanco)	2.572	2009–2026
PETR4 (Petrobras)	1.775	2009–2026
VALE3 (Vale)	1.525	2009–2026
Total	5.872	

3.2 Engenharia de features

O módulo `yahoo_finance.py` obtém dados OHLCV via `yfinance` e calcula 11 *features* técnicas por dia: fechamento, volume, retorno diário, médias móveis (7 e 21 dias), volatilidade (desvio-padrão 21 dias) e 5 valores defasados. O módulo `news_embedder.py` transforma cada artigo em um vetor de 1.024 dimensões via Ollama (`qwen3-embedding:4b`), com agregação diária por média simples. As *features* são combinadas via *left join* por data com *forward-fill* (*forward-fill*: propagação do último valor conhecido para dias sem publicação de notícias). O *dataset* resultante contém $1.227 \text{ dias} \times 1.035 \text{ features}$ (11 de preço + 1.024 de *embeddings*).

3.3 Modelos iniciais com embeddings genéricos

O alvo binário é definido como 1 se $\text{Close}[t + 21] > \text{Close}[t]$ (horizonte $h = 21$ dias), com desbalanceamento de 59% “Sobe” / 41% “Desce”. Este horizonte é mantido nos Capítulos 3 e 4; o Capítulo 5 também explora $h = 5$ dias na varredura de horizontes (`horizon_sweep.ipynb`). Os *embeddings* são reduzidos para 32 componentes via PCA (*Principal Component Analysis*), ajustado exclusivamente no conjunto de treino para evitar vazamento de dados. A escolha de 32 componentes foi baseada na inspeção da curva de variância explicada acumulada, conforme reportado em `3.model_training/feature_engineering.ipynb`: os primeiros 32 componentes retêm 61,4% da variância total dos *embeddings* do conjunto de treino. A validação segue *split* cronológico 70/15/15. Neste protocolo, os primeiros 70% dos dias formam o conjunto de treino, os 15% seguintes o conjunto de validação, e os 15% finais o conjunto de teste, mantendo a ordem cronológica e evitando vazamento de dados futuros.

Tabela 2 – Resultados com *embeddings* genéricos Ollama (Etapa 3). **Nota:** estimativas pontuais de uma única semente e uma única janela temporal, reportadas para continuidade narrativa; o Capítulo 5 aplica avaliação multi-semente e multi-*fold* aos resultados da Etapa 4.

Modelo	Arquitetura	ROC-AUC
BiLSTM Original	2 camadas, 128 <i>hidden</i> , 30% <i>dropout</i>	0,443
BiLSTM Reduzido	1 camada, 32 <i>hidden</i> , 50% <i>dropout</i>	0,505
Transformer	2 camadas, 4 cabeças, $d_{\text{model}} = 64$	0,568
XGBoost	300 árvores, profundidade 4	0,610

Todos os modelos apresentaram desempenho próximo do acaso, sugerindo que *embeddings* genéricos de alta dimensionalidade não são adequados para esta tarefa. O Capítulo 4 testa uma representação alternativa.

4 Sentimento Financeiro Específico via FinBERT-PT-BR

4.1 Hipótese

Os resultados do Capítulo 3 sugeriram que os *embeddings* genéricos contêm ruído semântico irrelevante para o domínio financeiro. Este capítulo testa se uma representação compacta e específica — 5 *features* de sentimento financeiro extraídas com o FinBERT-PT-BR (SOUZA; CARVALHO; CALADO, 2023) — pode ser mais informativa.

4.2 O modelo FinBERT-PT-BR

O FinBERT-PT-BR é um modelo BERT (DEVLIN et al., 2019) pré-treinado e *fine-tuned* em corpora financeiros brasileiros. Para cada artigo, produz três *logits* correspondentes às classes POSITIVO, NEGATIVO e NEUTRO. Diferentemente de modelos de sentimento genéricos, foi calibrado para vocabulário financeiro específico.

4.3 Pipeline de extração e resultados

O corpus FinBERT cobre 1.207 dias úteis — 20 dias a menos que o dataset de embeddings (1.227 dias) — porque o alinhamento por data entre os artigos coletados e os preços de mercado resultou em um período ligeiramente diferente após o pré-processamento de cada fonte. A extração segue os passos: inferência em *batch* (32 artigos, entrada **título + resumo**, 512 *tokens*); persistência dos *logits* brutos; agregação diária em 5 *features* (**n_articles**, **mean_logit_pos/neg/neu**, **mean_sentiment**); junção temporal com *forward-fill*. O dataset resultante: 1.207 dias $\times$ 16 *features*.

Granularidade temporal e risco de *look-ahead*. O risco de *look-ahead* ocorre quando informações disponíveis apenas após o instante t são incorporadas como *features* para prever t , inflando artificialmente as métricas de desempenho. Os artigos possuem *timestamps* ISO 8601, mas a agregação descarta o horário. Artigos pós-fechamento da B3 (~ 17 h BRT) são atribuídos ao dia t ; o deslocamento pode exceder 1 dia em dias consecutivos sem publicação. O impacto é atenuado pelo horizonte de 5–21 dias e pela média diária. A proporção exata de artigos publicados após o fechamento do pregão não foi auditada sistematicamente; a análise de *timestamps* necessária para quantificar este risco é reconhecida como uma limitação do trabalho (Seção 6.3). O impacto é mitigado pelo horizonte de 5–21 dias e pela agregação diária por média.

Tratamento de desbalanceamento de classe. O alvo binário apresenta desbalanceamento de 59% “Sobe” / 41% “Desce” no conjunto de treino. Para mitigar o viés em direção à classe majoritária, todos os modelos recebem compensação explícita: os modelos neurais (BiLSTM, Transformer, TCN) utilizam `BCEWithLogitsLoss` com `pos_weight =  $n_{\text{desce}}/n_{\text{sobe}} \approx 1,38$` ; o XGBoost utiliza o parâmetro `scale_pos_weight` com o mesmo valor; e os modelos *sklearn* (Logistic Regression, Random Forest) utilizam `class_weight="balanced"`. Apesar desta compensação, o Transformer ainda exibe forte viés para a classe majoritária (prevendo “Desce” apenas 11 vezes em 177 amostras), indicando que o desbalanceamento é um fator contribuinte mas não a causa principal do colapso de predição documentado no Capítulo 5.

Tabela 3 – Comparação Etapa 3 (*embeddings*) vs Etapa 4 (sentimento FinBERT). **Nota:** todos os valores são estimativas pontuais de uma única semente e uma única janela temporal, sem intervalos de confiança — esta omissão é uma das motivações para a investigação do Capítulo 5.

Modelo	AUC Etapa 3	AUC Etapa 4	Δ
BiLSTM Original	0,443	0,500	+0,057
BiLSTM Reduzido	0,505	0,477	−0,028
XGBoost	0,610	0,670	+0,060
Transformer	0,568	0,709	+0,141

O BiLSTM Reduzido registrou regressão de $-0,028$ ao trocar *embeddings* por sentimento FinBERT. Uma explicação plausível é que a arquitetura compacta (1 camada, 32 unidades ocultas, 50% de *dropout*) é insuficiente para aproveitar a especificidade adicional das *features* FinBERT dado o conjunto de treino pequeno: a regularização agressiva que beneficia representações de alta dimensionalidade pode sobrepenalizar uma entrada de apenas 5 *features*, reduzindo a capacidade de generalização.

O Transformer atinge $\text{ROC-AUC} = 0,709$ (acurácia 76,3%, 177 amostras). Porém, $\text{precision}(\text{Desce}) = 1,00$ com $\text{recall}(\text{Desce}) = 0,15$ — o modelo prevê “Desce” apenas 11 vezes em 177 amostras. Três observações motivam a investigação do Capítulo 5: (1) matriz de confusão assimétrica; (2) acurácia próxima da classe majoritária ($\sim 69\%$); (3) ausência de intervalos de confiança e múltiplas sementes.

5 Investigação Metodológica e o Viés da Avaliação por Janela Única

5.1 Motivação e protocolo geral

Este capítulo aplica protocolos progressivamente mais rigorosos para determinar se esse valor inicial sobrevive a escrutínio metodológico. A Tabela 4 sumariza os 13 experimentos realizados (mais de 1.500 treinamentos). As funções utilitárias utilizadas em todos os experimentos são detalhadas no Apêndice A.

Tabela 4 – Experimentos do Capítulo 5.

Experimento	Notebook	Runs
Baseline autoregressivo	dumb_baseline.ipynb	4
Baselines ingênuos	naive_baselines.ipynb	3
Controle de dimensionalidade	dimensionality_control.ipynb	20
Bootstrap CI (Etapa 4)	bootstrap_stage4.ipynb	1
Multi-seed em ITUB4	multi_seed.ipynb	40
Multi-seed $\times$ multi-ticker	multi_seed_multi_ticker.ipynb	120
Ensemble + backtest	ensemble_backtest.ipynb	20
Expanding-window CV	expanding_window_cv.ipynb	145
Varredura de horizontes	horizon_sweep.ipynb	6
VALE3 <i>deep-dive</i>	vale3_deepdive.ipynb	880
Ablation PRICE/SENT/PRICE+SENT	ablation_price_vs_sentiment.ipynb	225
Poder estatístico	power_analysis.ipynb	—
Validação TCN Stage 5b	tcn_validation.ipynb	45
Total		~1.510

Todos os hiperparâmetros dos modelos foram fixados ao longo dos experimentos, sem otimização por *fold*: XGBoost (300 árvores, profundidade 4, *learning rate* 0,05); Transformer (2 camadas, 4 cabeças, $d_{\text{model}} = 64$, *dropout* 0,2, 200 épocas com *early stopping* por perda de validação, paciência 10); TCN ([32,32], *kernel size* 3, *dropout* 0,2). A decisão de não otimizar hiperparâmetros por *fold* foi deliberada: o objetivo não era maximizar desempenho, mas medir a robustez do resultado original sob variação de janela e semente.

O experimento *Ensemble + backtest* (20 treinamentos) combinou as predições do Transformer e do XGBoost via média ponderada por AUC de validação e avaliou a estratégia de trading resultante; os resultados não evidenciaram ganho sobre o *baseline* autoregressivo isolado, e o experimento foi descontinuado em favor da análise *multi-seed*.

Respostas a questões metodológicas. O *early stopping* nos modelos neurais é baseado na perda de validação (não no AUC), com paciência de 10 épocas — o colapso

bimodal não é um artefato de *early stopping*, pois ocorre independentemente do critério de parada. Os *folds* da CV *expanding-window* utilizam passo de 90 dias com janelas de teste de 90 dias, resultando em adjacência entre janelas de teste consecutivas, com sobreposição entre a janela de validação de um *fold* e a janela de teste do *fold* subsequente; embora isto viole a independência estrita exigida pelo teste de Wilcoxon, o efeito é conservador (infla correlação, não produz significância espúria em resultados nulos). As 5 *features* de sentimento FinBERT são normalizadas via `StandardScaler` ajustado exclusivamente no conjunto de treino de cada *fold*. Por fim, a conclusão nula deve ser qualificada: dado o Tamanho Mínimo de Efeito Detectável (MDE) de 0,132–0,221, efeitos reais menores que $\Delta\text{AUC} \approx 0,13$ seriam indetectáveis neste desenho experimental (o MDE calculado varia de 0,132 a 0,221 dependendo do tamanho da janela de teste) — o resultado é portanto “nenhum efeito detectável neste tamanho amostral”, não “nenhum efeito”.

5.2 Baseline autoregressivo e baselines ingênuos

Um XGBoost (CHEN; GUESTRIN, 2016) treinado em 5 *features* de preço (`return`, `lag_1`, `lag_5`, `Volume`, `std21`) — subconjunto das 11 *features* técnicas calculadas no Capítulo 3, selecionadas por representar os sinais de momentum, volume e volatilidade mais diretamente relacionados à previsão de direção — atinge $\text{AUC} = 0,658$ [0,565; 0,744]. Para contextualizar, três preditores ingênuos foram avaliados. A **classe majoritária** sempre prediz “Sobe” (a classe majoritária do conjunto de treino), servindo como limite inferior trivial. O ***coin flip*** amostra aleatoriamente uma predição com probabilidade igual ao *prior* da classe, simulando um preditor sem qualquer sinal. A **persistência** ($h = 21$) assume que a direção de preço no instante t se repete em $t + 21$, codificando uma hipótese de *momentum* de curtíssimo prazo.

Tabela 5 – Hierarquia de *baselines*: do ingênuo ao autoregressivo.

Preditor	Descrição	AUC [IC 95%]
Classe majoritária	Sempre prevê “Sobe”	0,500 [0,500; 0,500]
<i>Coin flip</i>	$P(\text{Sobe}) = \text{prior}$	0,500 [0,500; 0,500]
Persistência ($h = 21$)	Direção repete	0,474 [0,405; 0,543]
Autoregressivo (XGB)	5 features preço	0,658 [0,565; 0,744]

O controle de dimensionalidade (20 subconjuntos aleatórios de 5 dimensões Ollama) produz AUC médio de $0,509 \pm 0,057$, confirmando que a melhoria Etapa 3 $\rightarrow$ Etapa 4 reflete especificidade de domínio do FinBERT.

5.3 Reprodutibilidade e variância de semente

Sob recompilação com semente 42, o Transformer atinge $AUC = 0,442$ — diferença de 0,267 pontos ($22\times$ o desvio-padrão do *baseline*). Sob 20 sementes (Tabela 6), o Transformer exhibe distribuição bimodal (Figura 1): a distribuição é bimodal porque o modelo colapsa para um de dois estados degenerados dependendo da inicialização — ou prevê quase sempre “Sobe” ($AUC \approx 0$ ou 1, conforme a classe majoritária do teste coincida com a predição) ou quase sempre “Desce”. Não há um ponto de equilíbrio intermediário discriminativo porque o sinal preditivo real é insuficiente para ancorar a otimização fora desses mínimos locais degenerados.

Tabela 6 – Distribuição de AUC sobre 20 sementes (ITUB4, janela única).

Modelo	Média	Std	Mediana	Min	Max
Transformer + FinBERT	0,686	0,261	0,802	0,080	0,931
Baseline autoregressivo	0,641	0,012	0,638	0,615	0,660

O Transformer apresenta desvio-padrão de 0,261 — $21\times$ superior ao do *baseline* (0,012) — evidenciando instabilidade estrutural incompatível com uso em produção.




Figura 1 – Distribuição de AUC sobre 20 sementes em ITUB4. O Transformer (esquerda) exhibe distribuição bimodal com AUCs agrupados próximos de 0 e 1, enquanto o *baseline* (direita) é estável em torno de 0,64. Coeficiente de variação do Transformer: 38%.

5.4 Expanding-window cross-validation

Substituindo o *split* único por *CV expanding-window* (600 dias mínimo, validação/teste 90 dias, 5 *folds* $\times$ 5 sementes $\times$ 3 ativos $\times$ 2 modelos = 150 treinamentos programados; 145 realizados, descartando *folds* com conjuntos de teste degenerados):

A inversão é de grande magnitude ($d \approx 6,4$, calculado como a diferença média de AUC entre modelos dividida pelo desvio-padrão do *baseline* ao longo dos *folds*: $0,255/0,04$

Tabela 7 – AUC médio sob *expanding-window* CV.

Ativo	Baseline XGB	Transformer	Δ
ITUB4	0,700	0,445	−0,255
PETR4	0,702	0,447	−0,255
VALE3	0,599	0,635	+0,036
Média	0,667	0,509	−0,158




Figura 2 – AUC por *fold* ao longo do tempo sob *expanding-window* CV, para os 3 ativos. A linha do *baseline* (vermelho) permanece consistentemente acima do Transformer (azul) em ITUB4 e PETR4, com barras de erro menores. As barras de erro representam o desvio-padrão do AUC entre as 5 sementes por *fold*.

(desvio-padrão do AUC do *baseline* XGB ao longo dos 5 *folds* em ITUB4, derivado dos dados da Figura 2)). A exceção aparente em VALE3 (+0,036) motivou um *deep-dive* com protocolo deliberadamente mais rigoroso (52 *folds* $\times$ 10 sementes $\times$ 2 modelos = 1.040 treinamentos programados; 880 realizados) do que o utilizado na análise principal (5 *folds* $\times$ 5 sementes), de forma a garantir conclusão robusta sobre o único ativo com $\Delta > 0$. O *deep-dive* revelou o resultado como não significativo (Wilcoxon $p = 0,194$). A Figura 3 mostra a distribuição bimodal do Transformer em VALE3.

5.5 Ablation: o sentimento adiciona algo?

O XGBoost foi escolhido como modelo de referência para esta ablação por ser o *baseline* mais estável ao longo dos experimentos anteriores — ao contrário do Transformer, que sofre colapso bimodal e tornaria difícil separar o efeito das *features* do efeito da arquitetura. PRICE denota as 5 *features* autoregressivas de preço; SENT denota as 5 *features* de sentimento FinBERT-PT-BR; PRICE+SENT denota a concatenação das duas representações. O desenho experimental segue o esquema 5 *folds* $\times$ 5 sementes $\times$ 3 ativos $\times$ 3 configurações de *features* = 225 treinamentos. Os resultados por configuração são apresentados na Tabela 8.

O ganho do sentimento é $\Delta = +0,003$ (Wilcoxon $p = 0,49$, IC 95% $[-0,012; +0,018]$). A Figura 4 ilustra essa equivalência: as distribuições de AUC de PRICE e PRICE+SENT se sobrepõem em todos os ativos, enquanto SENT isolado opera abaixo do acaso. A análise




Figura 3 – Distribuição de 880 AUCs ($52 \text{ folds} \times 10 \text{ sementes}$) em VALE3. O *baseline* (esquerda) produz distribuição unimodal centrada em $\sim 0,55$. O Transformer (direita) produz distribuição bimodal severa com picos em $\text{AUC} < 0,05$ e $\text{AUC} > 0,95$ — assinatura de classificador degenerado — padrão característico de um modelo que colapsa para predição constante independentemente da entrada.

Tabela 8 – Ablation: PRICE vs SENT vs PRICE+SENT. $\Delta = \text{PRICE+SENT} - \text{PRICE}$.

Ativo	PRICE	SENT	PRICE+SENT	Δ
ITUB4	0,684	0,436	0,651	−0,033
PETR4	0,692	0,494	0,676	−0,016
VALE3	0,609	0,510	0,667	+0,058
Média	0,662	0,480	0,665	+0,003

de poder (HANLEY; MCNEIL, 1982) confirma que este efeito está 44–74× abaixo do MDE (0,132–0,221 para N entre 60 e 177).

5.6 Validação do TCN Stage 5b

O TCN [32,32] (BAI; KOLTER; KOLTUN, 2018) — melhor resultado prático ($\text{AUC} = 0,643$ sob janela única), cuja arquitetura completa é detalhada no Apêndice B — atinge $0,513 \pm 0,102$ sob 20 sementes e $0,556$ sob CV *expanding-window*, inferior ao *baseline* (0,700). A Figura 5 sumariza a validação.

5.7 Síntese

A conclusão unificada dos experimentos deste capítulo é a seguinte:




Figura 4 – Distribuição de AUC por configuração de *features* e ativo, sob *expanding-window* CV. PRICE e PRICE+SENT são estatisticamente indistinguíveis; SENT sozinho opera abaixo do acaso.




Figura 5 – Validação do TCN [32,32]. Esquerda: distribuição multi-seed (20 sementes) — 60% das sementes ficam abaixo de 0,50. Direita: distribuição *expanding-window* CV — AUC médio de 0,556, inferior ao *baseline*.

Sob avaliação metodologicamente correta (*multi-fold*, *multi-sementes*, com intervalos de confiança e *ablation* de *features*), as *features* de sentimento FinBERT-PT-BR não adicionam sinal preditivo mensurável a um *baseline* autoregressivo de cinco *features* de preço, em nenhum dos três ativos testados. O resultado da janela única é um artefato dessa forma de avaliação — combinação de variância de semente, viés de amostragem da janela de teste e colapso bimodal da arquitetura.

Esta conclusão aplica-se especificamente à representação de sentimento adotada — cinco *features* agregadas diariamente do FinBERT-PT-BR — e não pode ser generalizada a toda forma possível de incorporar informação textual em modelos de predição financeira.

A análise *multi-seed* demonstrou que esse valor previamente observado não é reprodu-

tível: sob 20 sementes aleatórias em ITUB4, o Transformer exhibe desvio-padrão de 0,261 (coeficiente de variação de 38%), enquanto o *baseline* autoregressivo permanece estável com desvio-padrão de 0,012. O *deep-dive* em VALE3, único ativo com $\Delta > 0$ na análise de 5 *folds*, foi aprofundado para 52 *folds* $\times$ 10 sementes (880 treinamentos realizados), revelando o aparente ganho como não significativo (Wilcoxon $p = 0,194$).

A validação cruzada *expanding-window* inverteu o resultado qualitativo: o Transformer apresentou AUC médio de 0,509 contra 0,667 do *baseline* ($d \approx 6,4$). O experimento de *ablation*, conduzido com 225 treinamentos (XGBoost, 3 ativos, 5 *folds*, 5 sementes), quantificou diretamente a contribuição do sentimento: $\Delta = +0,003$ ao adicionar as 5 *features* FinBERT ao conjunto de preço (Wilcoxon $p = 0,49$, IC 95% *bootstrap* $[-0,012; +0,018]$). A análise de poder confirmou que esse efeito está 44–74 $\times$ abaixo do mínimo detectável pelo tamanho amostral disponível.

O Capítulo 6 discute as implicações deste resultado, propõe protocolos mínimos de avaliação e indica direções para trabalhos futuros.

6 Conclusão

6.1 Contribuições

Este trabalho oferece três contribuições:

1. **Pipeline técnico replicável.** O sistema de coleta de notícias (InfoMoney), extração de sentimento (FinBERT-PT-BR) e integração com dados de mercado (Yahoo Finance) está integralmente versionado e pode ser reproduzido por outros pesquisadores.
2. **Demonstração empírica do viés de janela única.** A inversão de AUC 0,709 (janela única) para $\sim 0,51$ (multi-fold) é documentada com mais de 1.500 execuções e suporte estatístico formal. Estudos anteriores documentaram parcialmente esse fenômeno em outros mercados: Ding et al. (2015) avaliaram modelos de *event-driven prediction* em dados do S&P 500 com *split* único sem análise de variância de semente; Hu et al. (2018) reportaram resultados de predição de tendência em ações chinesas com protocolo de janela única sem intervalos de confiança; e Shah, Isah e Zulkernine (2019) catalogaram que a maioria dos estudos de *sentiment analysis* para finanças não reporta resultados fora da amostra original. (A caracterização das práticas de avaliação desses estudos segue a revisão sistemática de Shah, Isah e Zulkernine (2019), que catalogou os protocolos predominantes na literatura de predição financeira com NLP.) O presente trabalho complementa essa literatura com a primeira demonstração quantificada em dados brasileiros, com suporte estatístico formal (1.500+ execuções, Wilcoxon, IC *bootstrap*) e inversão de conclusão qualitativa documentada.
3. **Proposição de protocolos mínimos.** O trabalho propõe seis práticas para pesquisa em ML financeiro: (1) reportar IC *bootstrap*; (2) treinar com ≥ 10 sementes (ver Tabela 6); (3) usar CV *expanding-window* (ver Tabela 7); (4) comparar contra *baseline* autoregressivo; (5) monitorar distribuição de predições — a distribuição bimodal de AUC do Transformer (Figura 1), com picos próximos de 0 e 1, é a assinatura do colapso degenerado que motiva esta prática; (6) auditar correlação validação-teste.

6.2 Reflexão sobre o processo de autocorreção

A experiência de construir um *pipeline* completo, obter esse resultado preliminar aparentemente forte e depois desmontá-lo sistematicamente foi a lição mais valiosa deste trabalho. O viés de confirmação — a tendência natural de aceitar resultados que concordam com a hipótese — operou de forma invisível nas primeiras etapas: a ausência de intervalos de

confiança, a fixação de uma única semente e o *split* único não pareciam problemáticos porque o resultado “fazia sentido”. A contribuição do Capítulo 5 não é a descoberta de que o sentimento não funciona — é a demonstração de quão fácil é produzir evidência aparente de que ele funciona, usando protocolos que a própria comunidade de ML financeiro considera aceitáveis.

Os seis protocolos propostos na Seção anterior não são originais: o uso de múltiplas sementes, CV temporal e *baselines* autoregressivos são recomendações explícitas de Prado (2018). A contribuição deste trabalho é mostrar, em um caso concreto com dados brasileiros, a magnitude do dano causado por ignorá-los: uma inversão da métrica inicial para $\sim 0,51$, que transforma uma conclusão positiva em negativa.

6.3 Limitações

As principais limitações incluem: (1) fonte única de notícias (InfoMoney), com viés editorial voltado ao investidor de varejo e cobertura heterogênea entre ativos (2.572 artigos para ITUB4 vs 1.525 para VALE3); (2) apenas 3 ações de grande capitalização da B3, limitando a validade externa; (3) horizonte de previsão restrito a 5 e 21 dias úteis; (4) a conclusão sobre o sentimento se aplica à representação específica adotada (5 *features* agregadas diariamente do FinBERT-PT-BR), não a toda forma possível de codificar informação textual; (5) a *ablation* (Seção 5.5) foi conduzida com $h = 21$, enquanto o TCN Stage 5b utiliza $h = 5$ — uma *ablation* com $h = 5$ fortaleceria a comparação; contudo, dado que o efeito médio do sentimento sobre 225 treinamentos é $\Delta = +0,003$ com IC 95% $[-0,012; +0,018]$, é improvável que a conclusão direcional (sentimento não adiciona valor mensurável) se inverta com a mudança de horizonte; (6) a instabilidade arquitetural do Transformer (colapso bimodal documentado em todas as configurações testadas) impede a atribuição causal entre qualidade das *features* e desempenho do modelo; arquiteturas mais estáveis poderiam fornecer avaliação mais limpa do valor do sentimento.

6.4 Trabalhos futuros

Cinco direções são sugeridas: (1) diversificação de fontes textuais (comunicados CVM, *analyst reports*, redes sociais); (2) teste de arquiteturas menos propensas a colapso bimodal; (3) generalização para outros mercados; (4) estudo formal da anticorrelação validação-teste; (5) investigação de métricas ajustadas por desbalanceamento de classe (*balanced accuracy*, coeficiente de Matthews) como alternativa à AUC em conjuntos com *class imbalance* severo.

Referências

- ARACI, D. FinBERT: Financial sentiment analysis with pre-trained language models. *arXiv preprint arXiv:1908.10063*, 2019. Citado 2 vezes nas páginas 9 e 13.
- BAI, S.; KOLTER, J. Z.; KOLTUN, V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint arXiv:1803.01271*, 2018. Citado 2 vezes nas páginas 14 e 24.
- BAILEY, D. H. et al. Pseudo-mathematics and financial charlatanism: The effects of backtest overfitting on out-of-sample performance. *Notices of the American Mathematical Society*, v. 61, n. 5, p. 458–471, 2014. Citado 2 vezes nas páginas 10 e 14.
- CAVALCANTE, R. C. et al. Computational intelligence and financial markets: A survey and future directions. *Expert Systems with Applications*, v. 55, p. 194–211, 2016. Survey incluindo aplicações ao mercado brasileiro. Citado na página 13.
- CAWLEY, G. C.; TALBOT, N. L. C. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, v. 11, p. 2079–2107, 2010. Citado na página 14.
- CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.: s.n.], 2016. p. 785–794. Citado 2 vezes nas páginas 14 e 21.
- DEVLIN, J. et al. BERT: Pre-training of deep bidirectional transformers for language understanding. In: *Proceedings of the Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*. [S.l.: s.n.], 2019. p. 4171–4186. Citado na página 18.
- DING, X. et al. Deep learning for event-driven stock prediction. In: *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI)*. [S.l.: s.n.], 2015. p. 2327–2333. Citado 2 vezes nas páginas 13 e 27.
- FAMA, E. F. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, v. 25, n. 2, p. 383–417, 1970. Citado 2 vezes nas páginas 9 e 12.
- FISCHER, T.; KRAUSS, C. Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, v. 270, n. 2, p. 654–669, 2018. Citado 3 vezes nas páginas 9, 13 e 14.
- HANLEY, J. A.; MCNEIL, B. J. The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, v. 143, n. 1, p. 29–36, 1982. Citado 2 vezes nas páginas 14 e 24.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997. Citado na página 13.
- HU, Z. et al. Listening to Chaotic Whispers: A deep learning framework for news-oriented stock trend prediction. *arXiv preprint arXiv:1712.02136*, 2018. Citado 2 vezes nas páginas 13 e 27.

- KELLY, B. T.; XIU, D. Financial machine learning. *Foundations and Trends in Finance*, v. 13, n. 3-4, p. 205–363, 2023. Citado 2 vezes nas páginas 12 e 13.
- LO, A. W. The adaptive markets hypothesis. *Journal of Portfolio Management*, v. 30, n. 5, p. 15–29, 2004. Citado 2 vezes nas páginas 9 e 12.
- LOUGHRAN, T.; MCDONALD, B. When is a liability not a liability? textual analysis, dictionaries, and 10-ks. *The Journal of Finance*, v. 66, n. 1, p. 35–65, 2011. Citado na página 12.
- LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, v. 30, 2017. Citado 2 vezes nas páginas 6 e 14.
- MIKOLOV, T. et al. Distributed representations of words and phrases and their compositionality. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2013. v. 26. Citado na página 12.
- PENNINGTON, J.; SOCHER, R.; MANNING, C. D. GloVe: Global vectors for word representation. In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. [S.l.: s.n.], 2014. p. 1532–1543. Citado na página 13.
- PRADO, M. López de. *Advances in Financial Machine Learning*. Hoboken: Wiley, 2018. Citado 4 vezes nas páginas 10, 14, 15 e 28.
- SHAH, D.; ISAH, H.; ZULKERNINE, F. Stock market analysis: A review and taxonomy of prediction techniques. *International Journal of Financial Studies*, v. 7, n. 2, p. 26, 2019. Citado 2 vezes nas páginas 13 e 27.
- SOUZA, G. C. B. d.; CARVALHO, R. L. G.; CALADO, A. d. A. FinBERT-PT-BR: Análise de sentimento de textos em português do mercado financeiro. *Anais do Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana (STIL)*, 2023. Citado 5 vezes nas páginas 2, 3, 9, 13 e 18.
- VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2017. v. 30. Citado 3 vezes nas páginas 2, 3 e 14.
- XU, Y.; COHEN, S. B. Stock movement prediction from tweets and historical prices. In: *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*. [S.l.: s.n.], 2018. p. 1970–1979. Citado 2 vezes nas páginas 9 e 13.

APÊNDICE A – Funções utilitárias de avaliação

O módulo `eval_utils.py` concentra as funções reutilizadas por todos os experimentos do Capítulo 5. As funções principais são reproduzidas abaixo.

Listing A.1 – Intervalo de confiança *bootstrap* para ROC-AUC.

```

1 def bootstrap_auc_ci(y_true, y_score, n_boot=1000,
2                       alpha=0.05, seed=42):
3     rng = np.random.default_rng(seed)
4     n = len(y_true)
5     aucs = np.empty(n_boot)
6     for i in range(n_boot):
7         idx = rng.integers(0, n, size=n)
8         if len(np.unique(y_true[idx])) < 2:
9             aucs[i] = np.nan
10            continue
11        aucs[i] = roc_auc_score(y_true[idx], y_score[idx])
12    aucs = aucs[~np.isnan(aucs)]
13    auc_point = roc_auc_score(y_true, y_score)
14    lower = float(np.quantile(aucs, alpha / 2))
15    upper = float(np.quantile(aucs, 1 - alpha / 2))
16    return float(auc_point), lower, upper

```

Listing A.2 – Split temporal walk-forward 70/15/15.

```

1 def walk_forward_split(df, train_frac=0.70,
2                        val_frac=0.15):
3     n = len(df)
4     n_train = int(n * train_frac)
5     n_val = int(n * val_frac)
6     train = df.iloc[:n_train]
7     val = df.iloc[n_train:n_train + n_val]
8     test = df.iloc[n_train + n_val:]
9     return train, val, test

```

APÊNDICE B – Arquitetura TCN

A TCN (*Temporal Convolutional Network*) utiliza blocos de convolução causal dilatada com conexões residuais. A configuração TCN [32,32] contém duas camadas com 32 filtros cada, *kernel size* 3 e dilatações [1,2].

Listing B.1 – Bloco convolucional causal da TCN.

```

1 class CausalConv1dBlock(nn.Module):
2     def __init__(self, in_ch, out_ch, kernel_size,
3                 dilation, dropout=0.2):
4         super().__init__()
5         padding = (kernel_size - 1) * dilation
6         self.conv1 = nn.Conv1d(in_ch, out_ch,
7                                kernel_size, padding=padding,
8                                dilation=dilation)
9         self.conv2 = nn.Conv1d(out_ch, out_ch,
10                                kernel_size, padding=padding,
11                                dilation=dilation)
12         self.chomp = padding
13         self.relu = nn.ReLU()
14         self.dropout = nn.Dropout(dropout)
15         self.downsample = (nn.Conv1d(in_ch, out_ch, 1)
16                             if in_ch != out_ch else None)
17
18     def forward(self, x):
19         out = self.dropout(self.relu(
20             self.conv1(x)[: , : , :-self.chomp]))
21         out = self.dropout(self.relu(
22             self.conv2(out)[: , : , :-self.chomp]))
23         res = (self.downsample(x)
24               if self.downsample else x)
25         return self.relu(out + res)

```